



DIP/FPUNA

# **MEJORA DEL CONTRASTE DE IMÁGENES A COLOR UTILIZANDO UN FRAMEWORK DE OPTIMIZACIÓN MULTIOBJETIVO**

**Luis Guillermo Moré Rodríguez**

Orientadores: Prof. Diego Pedro Pinto Roa, Dr.  
Prof. José Luis Vázquez Noguera, M.Sc.

Tesis presentada a la Facultad Politécnica de la Universidad Nacional de Asunción, como requisito para la obtención del Grado de Máster en Ciencias de la Computación.

ASUNCIÓN - PARAGUAY

Noviembre - 2017

**MEJORA DEL CONTRASTE DE IMÁGENES A COLOR  
UTILIZANDO UN FRAMEWORK DE OPTIMIZACIÓN  
MULTIOBJETIVO**

Luis Guillermo Moré Rodríguez

Aprobado en Agosto de 2017 por:

---

Prof. Miguel García Torres, Dr.

---

Prof. Diego Pinto Roa, Dr.

---

Prof. Diego Stalder, D.Sc.

---

Prof. Horacio Legal Ayala, Dr.

---

Prof. José Luis Vázquez Noguera, M.Sc.

Datos internacionales de Catalogación en la Publicación (CIP)  
DE BIBLIOTECA CENTRAL DE LA UNA

Moré Rodríguez, Luis Guillermo

Mejora del contraste de imágenes a color utilizando un framework de optimización multiobjetivo/ Luis Guillermo Moré Rodríguez. – Asunción, 2017.  
21 p. : il.

Tesis (Maestría en Ciencias de la Computación) – Facultad Politécnica ,  
2017.

Bibliografía.

1. Mejora de contraste. 2. Optimización Por Ejambre de Partículas. 3.  
Imágenes a color. I. Título.

CDD 519.4

*Dedicado a mi esposa Maura Soledad y a mis hijos Julio, Maira y Melisa.*

*Ustedes son el motor que me empuja hacia adelante.*

***Los amo.***

*Dedicado a mis padres Lino y María Egberta Ester.*

*Gracias por brindarme en esta vida su apoyo incondicional.*

***Julio César***

# Agradecimientos

Agradezco profundamente a Dios y a la Virgen María por todas las gracias que me han brindado, entre ellas mi gran familia, amigos, orientadores, profesores y colaboradores que hicieron posible este trabajo.

Agradezco al NIDTEC por brindarme la oportunidad.

Agradezco al CONACYT por la beca otorgada.

## MEJORA DEL CONTRASTE DE IMÁGENES A COLOR UTILIZANDO UN FRAMEWORK DE OPTIMIZACIÓN MULTIOBJETIVO

Autor: Luis Guillermo Moré  
Rodríguez

Orientadores: Diego Pedro Pinto Roa, Dr.  
José Luis Vázquez Noguera,  
M.Sc.

### RESUMEN

La mejora del contraste se utiliza como un preprocesamiento de otros algoritmos como la segmentación de imágenes, fusión de imágenes, entre otros. La mejora del contraste es de suma importancia, ya que una imagen con bajo contraste haría que estos algoritmos arrojen resultados indeseados. El bajo contraste de las imágenes puede darse por varios factores, como la iluminación deficiente o fallas con el medio de adquisición. El problema del bajo contraste se soluciona utilizando una técnica que realza la calidad visual de la imagen. La morfología matemática es una de las técnicas que mejora las imágenes con bajo contraste, y ha demostrado eficiencia en la mejora de la calidad de las imágenes en escala de grises. Para su aplicación en imágenes en color es necesario adoptar un espacio de color y determinar un orden para los componentes de los vectores de la imagen en color. Aplicaciones de diferentes áreas, como las ciencias médicas, ingenierías y geociencias, aplican la mejora del contraste en etapas de preprocesamiento.

En este trabajo se presenta un algoritmo que mejora la calidad visual de imágenes en escala de grises e imágenes en color. El algoritmo propuesto extrae características de la imagen en escalas múltiples utilizando la morfología matemática. La validación de la propuesta se realizó utilizando 200 imágenes en color de una base de datos pública. El tamaño de las imágenes en color son de  $481 \times 321$  y de  $321 \times 481$ . La comparación se realizó con algoritmos que modifican el histograma y otra que utiliza la transformada de top-hat multiescala. La valoración de los resultados experimentales se realizaron con métricas que evalúan el contraste local y global. El algoritmo propuesto obtuvo mejores valoraciones numéricas y visuales para todos los casos probados, tanto para imágenes en escala de grises e imágenes en color.

## CONTRAST ENHANCEMENT OF COLOR IMAGES USING A MULTI-OBJECTIVE OPTIMIZATION FRAMEWORK

Author: Luis Guillermo Moré Rodríguez

Advisors: Diego Pedro Pinto Roa, Dr.

José Luis Vázquez Noguera,  
M.Sc.

### SUMMARY

Contrast enhancement is used as a preprocessing of other algorithms such as image segmentation, image fusion, among others. Contrast enhancement is of utmost importance, since a low-contrast image would cause these algorithms to present undesired results. The low contrast of the images may be due to several factors, such as poor lighting or faults with the acquisition medium. The problem of low contrast is solved using a technique that enhances the visual quality of the image. Mathematical morphology is one of the techniques that improves images with low contrast, and has demonstrated efficiency in improving the quality of grayscale images. For its application in color images, it is necessary to adopt a color space and to determine an order for the components of the vectors of the color image. Applications of different areas, such as medical sciences, engineering and geosciences, use contrast enhancement in preprocessing stages.

This work presents an algorithm that improves the visual quality of grayscale images and color images. The proposed algorithm extracts image characteristics in multiple scales using mathematical morphology. The validation of the proposal was done using 200 color images from a public database. The size of the color images are  $481 \times 321$  and  $321 \times 481$ . The comparison was performed with algorithms that modify the histogram and another that uses the multiscale top-hat transform. The evaluation of the experimental results was done with metrics that evaluate the local and global contrast. The proposed algorithm obtained better numerical and visual evaluations for all cases tested, both for grayscale images and color images.

# ÍNDICE GENERAL

LISTA DE FIGURAS	X
LISTA DE TABLAS	XI
LISTA DE SÍMBOLOS	XII
LISTA DE ABREVIATURAS	XIV
<b>1. INTRODUCCIÓN</b>	<b>1</b>
1.1. Objetivos . . . . .	2
1.1.1. Objetivo General . . . . .	2
1.1.2. Objetivos específicos . . . . .	2
1.2. Estructura de la tesis . . . . .	2
<b>2. MARCO TEÓRICO</b>	<b>3</b>
2.1. Espacios de Color Adoptados . . . . .	3
2.1.1. Contrast Limited Adaptive Histogram Equalization (CLAHE)	4
2.1.2. Multi-Objective Particle Swarm Optimization (MOPSO) .	4
2.1.3. Entropía de la imagen . . . . .	5
2.1.4. Índice de Similaridad Estructural . . . . .	5
<b>3. FORMULACIÓN DEL PROBLEMA PLANTEADO Y PRO- PUESTA</b>	<b>7</b>
3.1. Formulación del problema planteado . . . . .	7
3.2. Propuesta . . . . .	8
<b>4. RESULTADOS Y DISCUSIÓN</b>	<b>10</b>
<b>5. CONCLUSIONES Y TRABAJOS FUTUROS</b>	<b>15</b>
5.1. Trabajos futuros . . . . .	15



<b>REFERENCIAS BIBLIOGRÁFICAS</b>	<b>16</b>
.1. <i>Histogram Equalization</i> (HE) . . . . .	20
.2. <i>Contrast Limited Adaptive Histogram Equalization</i> (CLAHE) . . .	20

# LISTA DE FIGURAS

4.1. Original Image. $\mathcal{H}_y = 0,207231$ , $SSIM_R = 1$ , $SSIM_G = 1$ , $SSIM_B = 1$ . . . . .	12
4.2. Enhanced Image. $\mathcal{H}_y = 0,611275$ , $SSIM_R = 0,00897331$ , $SSIM_G =$ $0,00823064$ , $SSIM_B = 0,00851013$ . . . . .	12
4.3. Enhanced Image. $\mathcal{H}_y = 0,0350595$ , $SSIM_R = 0,416776$ , $SSIM_G =$ $0,403636$ , $SSIM_B = 0,417654$ . . . . .	12
4.4. Enhanced Image using [MB]. $\mathcal{H}_y = 0,788927$ , $SSIM_R = 0,000204143$ , $SSIM_G = 0,0000526475$ , $SSIM_B = 0,0000518143$ . . . . .	12
4.5. Imágenes original y resultantes para la imagen de prueba Casa 1 .	12
4.6. Frente Pareto dibujado utilizando datos de la Tabla 4.2 . . . . .	13

## LISTA DE TABLAS

4.1.	Parámetros de entrada para <i>MOPSO</i> . . . . .	10
4.2.	Parámetros de entrada para <i>MOPSO</i> . . . . .	13
4.3.	Parámetros de entrada para <i>MOPSO</i> . . . . .	13
1.	Promedios de los tiempos de ejecución de algoritmo HE para las imágenes en escala de grises. . . . .	18
2.	Promedios de los tiempos de ejecución del algoritmo MMCE para las imágenes en escala de grises. . . . .	18
3.	Promedios de los tiempos de ejecución del algoritmo propuesto para las imágenes en escala de grises. . . . .	19

# LISTA DE SÍMBOLOS

$f$	Imagen original.....	??
$\mathbb{Z}$	Conjunto de números enteros .....	??
$\mathbb{R}$	Conjunto de números racionales .....	??
$m$	Valor asociado a un píxel dentro de un espacio de color .....	??
$c$	Componentes del valor asociado a un píxel.....	??
$j$	Nivel de intensidad .....	??
$f_k$	Componentes de $f$ .....	??
$L$	Máximo nivel de intensidad de una imagen.....	??
$h_{f_k}(j)$	Histograma del canal $f_k$ .....	??
$n_j$	Cantidad de ocurrencia de la intensidad $j$ en $f_k$ .....	??
$g$	Elemento estructurante .....	??
$(u,v)$	Coordenada espacial que representa un píxel de la imagen....	??
$(s,t)$	Coordenada espacial del elemento estructurante.....	??
$(f \oplus g)$	Dilatación de la imagen original $f$ por un elemento estructurante $g$ .....	??
$(f \ominus g)$	Erosión de la imagen original $f$ por un elemento estructurante $g$ .....	??
$(f \circ g)$	Apertura de la imagen original $f$ por un elemento estructurante $g$ .....	??
$(f \bullet g)$	Cierre de la imagen original $f$ por un elemento estructurante $g$ ??	??
$WTH$	Transformada de top-hat por apertura .....	??
$BTH$	Transformada de top-hat por cierre .....	??
$f_E$	Imagen con mejora de contraste.....	??
$f_1$	Componente R de $f$ .....	??
$f_2$	Componente G de $f$ .....	??
$f_3$	Componente B de $f$ .....	??
$w$	Función de pesos .....	??
$T$	Transformada escalar de una imagen.....	??
$n$	Número de iteraciones .....	??
$i$	Índice de iteraciones .....	??

$WTH_i$	$i$ -escalas de brillos . . . . .	??
$BTH_i$	$i$ -escalas de oscuridad . . . . .	??
$WTH_{i-1}^S$	$(i - 1)$ -diferencias en cascada de las escalas de brillo . . . . .	??
$BTH_{i-1}^S$	$(i - 1)$ -diferencias en cascada de las escalas de oscuridad . . . . .	??
$WTH_M$	Valores máximos de todas las escalas de brillos . . . . .	??
$BTH_M$	Valores máximos de todas las escalas de oscuridad . . . . .	??
$WTH_M^S$	Valores máximos de todas las escalas de brillos por sustracción	??
$BTH_M^S$	Valores máximos de todas las escalas de oscuridad por sustracción	??
	??	
$E(f)$	Intensidad media de la imagen $f$ . . . . .	??
$P(j)$	Probabilidad de ocurrencia del valor $j$ . . . . .	??
$\rho$	Valor del píxel central dentro de una ventana . . . . .	??
$\iota$	Valor medio de los vecinos de $\rho$ . . . . .	??
$\omega$	Contraste local . . . . .	??
$D$	Dominio de una imagen . . . . .	??
$\gamma$	Diferencia entre los canales $f_1$ y $f_2$ de una imagen . . . . .	??
$\beta$	Diferencia entre un medio de $(f_1 + f_2)$ y $f_3$ . . . . .	??
$\sigma_\gamma$	Desviación estándar de $\gamma$ . . . . .	??
$\sigma_\beta$	Desviación estándar de $\beta$ . . . . .	??
$\mu_\gamma$	Media aritmética de $\gamma$ . . . . .	??
$\mu_\beta$	Media aritmética de $\beta$ . . . . .	??

# LISTA DE ABREVIATURAS

RGB: Espacio de color RGB.

HSI: Espacio de color HSI.

HSV: Espacio de color HSV.

HE: *Histogram Equalization*.

CLAHE: *Contrast-Limited Adaptive Histogram Equalization*.

MMCE: *Multiscale Morphological Contrast Enhancement*.

C: *Contrast*.

CIR: *Contrast Improvement Ratio*.

CEF: *Color Enhancement Factor*.

# Capítulo 1

## INTRODUCCIÓN

En el Procesamiento Digital de Imágenes, la Mejora del Contraste es un proceso que consiste en la transformación de píxeles de una imagen, con la finalidad de realizar cambios de manera tal a resaltar uno o más objetos dentro de la imagen tratada. El objetivo principal del proceso de Mejora del Contraste es la de obtener una nueva imagen cuyo Contraste sea más adecuado para la aplicación específica que se utilizará después [GW02a]

La Mejora del Contraste es un paso de preprocesamiento fundamental para varias aplicaciones. Algunas de las aplicaciones que más se benefician de éste proceso se detallan a continuación:

- Imágenes Médicas (como ejemplos es posible tomar: el Diagnóstico Asistido por Computadora [Doi07], Imágenes de Tomografía Computarizada [EW93], y otros).
- Sensoreamiento Remoto [LKC14],
- Otras.

Las técnicas basadas en Ecualización del Histograma se mostraron extensivamente válidas para enfocar los problemas de Mejora del Contraste [PAA<sup>+</sup>87, Zui94, Kim97]. Las Meta-Heurísticas tales como la Optimización Mono-Objetivo, y también la Optimización Multi-Objetivo fueron testeadas satisfactoriamente de manera a resolver problemas de Mejora del Contraste en imágenes en escala de gris [MB, MBA<sup>+</sup>15, Sai99, HS13]. Sin embargo, la Optimización Multi-Objetivo aplicada a la Mejora del Contraste en imágenes a color supone dificultades adicionales, debido a que es necesario preservar la información de color presente dentro de dichas imágenes.

Ésta propuesta consiste en realizar pruebas con imágenes a color transformadas desde el espacio de colores *RGB* al espacio de colores *YCbCr* de manera a

realizar la Mejora de Contraste basada en Optimización Multi-Objetivo. Contrast Limited Adaptive Histogram Equalization (CLAHE) se aplica sobre el canal  $Y$  de la imagen de prueba, de manera a modificar el contraste, y la imagen resultante se transforma nuevamente a  $RGB$  de forma a evaluar la similaridad entre canales de color.

## 1.1. Objetivos

### 1.1.1. Objetivo General

Desarrollar un algoritmo de mejora de contraste para imágenes a color, utilizando un enfoque de Metaheurística Multi-Objetiva pura.

### 1.1.2. Objetivos específicos

- Desarrollar un nuevo algoritmo de Mejora del Contraste de imágenes a color basado en Metaheurísticas Multi-Objetivo.
- Demostrar la factibilidad del enfoque de Mejora de Contraste de imágenes a color basado en Metaheurísticas Multi-Objetivo puras.
- Encontrar alternativas de implementación que ayuden a subsanar problemas inherentes a los enfoques basados en Metaheurísticas Multi-Objetivo, cuando la cantidad de objetivos sobrepasa a tres.

## 1.2. Estructura de la tesis

El trabajo, en las secciones siguientes se organiza de la siguiente manera: en el capítulo 2, los conceptos fundamentales de éste trabajo se presentan; en el capítulo 3.2 se presenta el problema de Mejora de Contraste, y el enfoque de éste trabajo se muestra; en el capítulo 4 se discute en detalle los resultados obtenidos, y finalmente en el capítulo 5 se hacen algunos comentarios finales.



## Capítulo 2

# MARCO TEÓRICO

Éste capítulo presenta una introducción a los conceptos principales utilizados en éste trabajo.

### 2.1. Espacios de Color Adoptados

Las imágenes originales se representan utilizando el espacio de colores *RGB* [GW02b], el cual es un arreglo de pixeles de color de tamaño  $N \times M \times 3$ . Cada pixel de color está representado por un elemento  $[z_r \ z_g \ z_b]$  del arreglo previamente mencionado, donde  $z_r, z_g, z_b$  son los componentes rojo, verde y azul de un pixel de color en una ubicación específica. Las imágenes originales son luego transformadas al espacio de colores *YCbCr* [GW02b], el cual es una representación ampliamente utilizada en el video digital. La principal ventaja es que en esta representación *Y* representa la información de luminancia de la imagen, mientras que el componente *Cb* representa la diferencia entre el componente azul y un valor de referencia, mientras que el componente *Cr* es la diferencia entre el componente rojo y un valor de referencia. Otra ventaja importante de ésta representación es que la conversión desde *RGB*, y nuevamente hacia *RGB* es directa:

$$\begin{bmatrix} Y \\ C_b \\ C_r \end{bmatrix} = \begin{bmatrix} 16 \\ 128 \\ 128 \end{bmatrix} + \begin{bmatrix} 65,481 & 128,553 & 24,966 \\ -37,797 & -74,203 & 112,000 \\ 112,000 & -93,786 & -18,214 \end{bmatrix} \begin{bmatrix} R \\ G \\ B \end{bmatrix} \quad (2.1)$$

$$\begin{bmatrix} R \\ G \\ B \end{bmatrix} = \begin{bmatrix} Y + 1,402 \cdot (C_r - 128) \\ Y - 0,34414 \cdot (C_b - 128) - 0,71414 \cdot (C_r - 128) \\ Y + 1,772 \cdot (C_b - 128) \end{bmatrix} \quad (2.2)$$

### 2.1.1. Contrast Limited Adaptive Histogram Equalization (CLAHE)

### 2.1.2. Multi-Objective Particle Swarm Optimization (MOPSO)

Multi-Objective Particle Swarm Optimization (*MOPSO*) [NDGN<sup>+</sup>09] es un algoritmo metaheurístico bien conocido. ES una metaheurística bio-inspirada que simula el comportamiento de las bandadas de pájaros. En *PSO*, cada solución potencial del problema que se trata se denomina *particle* y la población actual de soluciones se llama *swarm*. Cada partícula  $\vec{x}$  realiza una búsqueda dentro de un espacio de búsqueda  $\Omega$ , y para cada generación  $t$ , cada solución  $\vec{x}$  se actualiza de acuerdo a:

$$\vec{x}_i(t) = \vec{x}_i(t-1) + \vec{v}_i(t) \quad (2.3)$$

Aquí,  $\vec{v}$  es un factor conocido como la velocidad, y está dado por:

$$\vec{v}_i(t) = w \cdot (t-1) + C_1 \cdot r_1 \cdot (\vec{x}_{p_i} - \vec{x}_i) + C_2 \cdot r_2 \cdot (\vec{x}_{g_i} - \vec{x}_i), \quad (2.4)$$

donde  $\vec{x}_{p_i}$  es la mejor solución que  $\vec{x}_i$  encontró hasta ahora,  $\vec{x}_{g_i}$  es la mejor solución que el enjambre completo encontró durante una iteración,  $w$  es un coeficiente conocido como el *peso de la inercia*, que controla la tasa de velocidad de la búsqueda de *PSO*;  $r_1$  y  $r_2$  son números aleatorios entre  $[0, 1]$ . Finalmente,  $C_1$  Y  $C_2$  son los coeficientes que controlan la ponderación entre partículas globales y locales durante la búsqueda.

En *MOPSO*, un *coeficiente de constricción*  $\chi$  se adopta de manera a controlar la velocidad de la partícula, como se describe abajo:

$$\chi = \frac{2}{2 - \varphi - \sqrt{\varphi^2 - 4\varphi}} \quad (2.5)$$

donde

$$\varphi = \begin{cases} C_1 + C_2 & \text{if } C_1 + C_2 > 4 \\ 0, & \text{if } C_1 + C_2 \leq 4 \end{cases} \quad (2.6)$$

Además, la velocidad en *MOPSO* se acota con la siguiente ecuación de cons-

tricción de velocidad:

$$v_{i,j}(t) = \begin{cases} \text{delta}_j & \text{if } v_{i,j}(t) > \text{delta}_j \\ -\text{delta}_j, & \text{if } v_{i,j}(t) \leq \text{delta}_j \\ v_{i,j}(t), & \text{otherwise} \end{cases} \quad (2.7)$$

donde

$$\text{delta}_j = \frac{\text{upper\_limit}_j - \text{lower\_limit}_j}{2} \quad (2.8)$$

### 2.1.3. Entropía de la imagen

La entropía de la imagen [KBD91] es una métrica que mide cuánta información está representada dentro de la imagen. La entropía y el contraste se relacionan de manera muy cercana a la distribución de intensidad de las imágenes, por lo que esta métrica es capaz de verificar las variaciones de contraste como consecuencia de las transformaciones de la imagen.

Primero, es necesario definir el *Histograma* de intensidades de una imagen  $H$  como sigue: Sea  $c_1, c_2, \dots, c_n$  el conteo de pixeles con intensidades  $i_1, i_2, \dots, i_n$  respectivamente, y sea también:

$$p_i = \frac{c_i}{N}, \quad \sum_{i=1}^n c_i = N, \quad i = 1, 2, \dots, n, \quad (2.9)$$

donde  $N$  es la suma total de pixeles mostrados en una imagen  $I$  y  $n$  es cada nivel de intensidad representable por el espacio de colores de  $I$ . Entonces,  $H$  se define como la distribución de probabilidad en el que cada  $p_i$  representa la probabilidad de ocurrencia de una intensidad  $i$ . Entonces, la Entropía de la Imagen se define de la siguiente manera:

$$\mathcal{H} = - \sum_{i=0}^{n-1} p_i \log_2(p_i) \quad \mathcal{H} \in \{0, \dots, \log_2(n)\} \quad (2.10)$$

### 2.1.4. Índice de Similaridad Estructural

El *Índice de Similaridad Estructural* (*SSIM*) [WBSS04] es una métrica bien conocida que mide atributos importantes de la imagen tales como la *Luminancia*, *Contraste* y la *Estructura*. *SSIM* tiene como objetivo principal medir la distorsión agregada a la imagen como consecuencia del proceso de Mejora del Contraste. *SSIM* es calculado por regiones, por lo tanto, dadas dos imágenes  $I_x$  y  $T_y$  que re-

presentan una imagen original y una mejorada, respectivamente, el índice  $SSIM$  se define como se muestra abajo:

$$SSIM(I, T) = \frac{(2\mu_{I_x}\mu_{T_y} + E_1)(2\sigma_{I_x T_y} + E_2)}{(\mu_{I_x}^2 + \mu_{T_y}^2 + E_1)(\sigma_{I_x}^2 + \sigma_{T_y}^2 + E_2)} \quad SSIM \in [0, 1] \quad (2.11)$$

donde  $\mu_{I_x}$ ,  $\mu_{T_y}$  son los promedios de intensidad de  $I_x$  y  $T_y$ , respectivamente;  $\sigma_{I_x}^2$  y  $\sigma_{T_y}^2$  son las varianzas de intensidad para  $I_x$  y  $T_y$ , respectivamente;  $\sigma_{I_x T_y}$  es la covarianza entre las intensidades  $I_x$  y  $T_y$ .  $E_1 = (K_1 L^2)$ , donde  $L$  es el rango dinámico de intensidades de los pixeles de la imagen, y  $K_1 \ll 1$  es una constante pequeña;  $E_2 = (K_2 L)^2$ , y  $K_2 \ll 1$ ; tanto  $E_1$  como  $E_2$  son constantes utilizadas para estabilizar la división cuando el denominador se acerca a cero.

## Capítulo 3

# FORMULACIÓN DEL PROBLEMA PLANTEADO Y PROPUESTA

En este capítulo se muestra una formulación del problema a resolver, además de la propuesta detallada de la implementación realizada.

### 3.1. Formulación del problema planteado

Dada una imagen a color  $I$ , con  $M \times N$  píxeles, y un vector  $\vec{x} = (\mathcal{R}_x, \mathcal{R}_y, \mathcal{C})$ , donde  $\mathcal{R}_x$  y  $\mathcal{R}_y$  son regiones contextuales y  $\mathcal{C}$  es el *Clip Limit*, se busca un conjunto de soluciones no dominadas  $\mathcal{X}$ , que simultáneamente maximicen las funciones objetivo  $f_1, f_2, f_3, f_4$ :

$$\mathcal{F} = [f_1(I, \vec{x}), f_2(I, \vec{x}), f_3(I, \vec{x}), f_4(I, \vec{x})]; \quad f_1, f_2, f_3, f_4 \in [0, 1] \quad (3.1)$$

donde:

- $T_y$  es el mapa de intensidades mejoradas, al aplicar  $\vec{x}$  a  $I_y$ ; ésto es:  $T_y = CLAHE(\vec{x}, I_y)$ .  $T_y$  e  $I_y$  son los canales  $Y$  de la representación  $YCbCr$  de las imágenes  $I$  y  $T$ , respectivamente,
- $f_1(I, \vec{x}) = \frac{\mathcal{H}(T)}{\log_2 L}$  es la Entropía Normalizada del mapa de intensidades mejoradas  $T_y$ , como se describió arriba,
- $f_2(I, \vec{x}) = SSIM(I_R, T_R)$  es la medición del  $SSIM$  entre  $I_R$  y  $T_R$ .  $I_R$  y  $T_R$  son los canales  $R$  de las representaciones  $RGB$  de  $I$  y  $T$ , respectivamente,
- $f_3(I, \vec{x}) = SSIM(I_G, T_G)$  es la medición del  $SSIM$  entre  $I_G$  y  $T_G$ .  $I_G$  y  $T_G$  son los canales  $G$  de las representaciones  $RGB$  de  $I$  y  $T$ , respectivamente,

- $f_2(I, \vec{x}) = SSIM(I_B, T_B)$  es la medición del  $SSIM$  entre  $I_B$  y  $T_B$ .  $I_B$  y  $T_B$  son los canales  $G$  de las representaciones  $RGB$  de  $I$  y  $T$ , respectivamente,

Acotados por:

- $\mathcal{R}_x \in [2, \dots, M]$  dentro de  $\mathbb{N}$ ,
- $\mathcal{R}_y \in [2, \dots, N]$  dentro de  $\mathbb{N}$ ,
- $\mathcal{C} \in (0, \dots, 1]$  dentro  $\mathbb{R}$ .

## 3.2. Propuesta

---

### Algorithm 1 MOPSO-CLAHE

---

**Require:** Imagen de entrada  $I$ , cantidad de partículas  $\Omega$ , iteraciones  $t_{max}$

```

1: Inicializar  $\omega$ ,  $c_1$ ,  $c_2$ ,  $t = 0$ ,  $lower\_limit_1$ ,  $lower\_limit_2$ ,  $lower\_limit_3$ ,  $upper\_limit_1$ ,  $upper\_limit_2$ ,  $upper\_limit_3$ ,  $\mathcal{X}$ 
2: while  $t < t_{max}$  do
3:   for cada  $i$ -ésima partícula do
4:     Calcular una nueva velocidad  $\vec{v}_i^t$  de la partícula utilizando las ecuaciones (2.4) and (2.7)
5:     Calculate new particle position  $\vec{x}_i^t$  using expression (2.3)
6:      $T = CLAHE(\vec{x}_i^t, I)$ 
7:      $f_i^t = f(I, \vec{x}_i^t)$ 
8:     if  $\vec{x}_i^t \succ \vec{x}_{p_i}^t$  then
9:       replace  $\vec{x}_{p_i}^t$  by  $\vec{x}_i^t$ 
10:    end if
11:    if  $\vec{x}_i^t \succ \vec{x}_{g_i}^t$  then
12:      Update the Pareto set  $\mathcal{X}$ 
13:    end if
14:     $t = t + 1$ 
15:  end for
16: end while
Ensure:  $\mathcal{X}$ 

```

---

**El Algoritmo 1** muestra cómo PSO-CLAHE Color Multi-Objetivo (*CMOPSO-CLAHE*) es implementado, de manera a sintonizar los parámetros de *CLAHE*. Los parámetros recibidos por *CLAHE* son almacenados por una partícula  $\vec{x} = (\mathcal{R}_x, \mathcal{Y}_x, \mathcal{C})$ , la imagen original  $I$  se transforma a su representación  $YCrCb$ , y  $\vec{x}$  es aplicado al canal  $Y$  de la representación, de manera a obtener un mapa de intensidades  $Y_T$ , el cual es utilizado para realizar la transformación inversa hacia  $RGB$ , para así obtener la imagen resultante  $T$ . Las imágenes resultantes son evaluadas de acuerdo a las métricas  $\mathcal{H}_Y$ ,  $SSIM_R$ ,  $SSIM_G$ ,  $SSIM_B$ , que son la entropía de las imágenes resultantes medidas en el canal  $Y$  de la representación  $YCrCb$  de dichas imágenes, y  $SSIM_R, SSIM_G, SSIM_B$  son las medidas  $SSIM$

de las imágenes original y resultantes utilizando los canales  $R, G, B$  de las representaciones  $RGB$  de las imágenes. Las soluciones no dominadas se almacenan finalmente en el conjunto Pareto. El proceso de *CMOPSO* – *CLAHE* se repite hasta que se alcanza un criterio de parada.

## Capítulo 4

# RESULTADOS Y DISCUSIÓN

Tabla 4.1: Parámetros de entrada iniciales para CMOPSO-CLAHE.

Parámetro	Valor	Parámetro	Valor
$lower\_limit_{\mathcal{R}_x}$	2	$upper\_limit_{\mathcal{R}_x}$	$M/2$
$lower\_limit_{\mathcal{R}_y}$	2	$upper\_limit_{\mathcal{R}_y}$	$N/2$
$lower\_limit_{\mathcal{C}}$	0	$upper\_limit_{\mathcal{C}}$	0.5
$\Omega$	100	$t_{max}$	100
$c_1\ min$	1.5	$c_1\ max$	2.5
$c_2\ min$	1.5	$c_2\ max$	2.5
$r_1\ min$	0.0	$r_1\ max$	1.0
$r_2\ min$	0.0	$r_2\ max$	1.0

Se realizaron pruebas utilizando 8 imágenes a color a partir del conjunto de datos disponible en <http://www.vision.caltech.edu/archive.html>. La tabla 4.1 muestra cómo *SMPSO* fué configurada para realizar las pruebas. Los detalles de implementación de *SMPSO* está disponible en [DNA10], mientras que los detalles de implementación para *CLAHE*,  $\mathcal{H}$  y *SSIM* están disponibles en [Bra00]. Para cada imagen de prueba, se realizaron 50 ejecuciones, y en promedio se encontraron 10 soluciones no dominadas. De las figuras (4.1,4.2,4.3) es realmente notable cómo se logra la Mejora del Contraste; también hay una relación de compromiso entre  $\mathcal{H}$  y  $SSIM_R, SSIM_G, SSIM_B$ . Es también notable a partir de la Figura (4.3) cómo los valores más altos de  $\mathcal{H}$  degradan severamente a la imagen, por lo que es necesario encontrar el balance correcto entre  $\mathcal{H}$  and  $SSIM_R, SSIM_G, SSIM_B$ . En la Figura (4.4) se muestra la imagen resultante mejorada utilizando la propuesta descrita en [MB]; es interesante remarcar que



la imagen resultante no alcanza una buena Mejora del Contraste; ésto es debido a que el enfoque Mono-Objetivo no utiliza la información del color de manera apropiada, y éste resultado es el mismo para otras imágenes de prueba. En la Tabla 4.2, se muestran los coeficientes de las métricas no dominadas, y en la última línea se muestran los coeficientes de métricas para la imagen (4.1), mejorada utilizando la propuesta Mono-Objetivo. A pesar de que se puede considerar que las métricas caen dentro del Frente Pareto, la información visual obtenida no es suficiente para afirmar que la propuesta mono-objetivo es factible para imágenes a color. Éstos resultados son similares en cada imagen de prueba utilizada.

width=45mm

(a) t



Figura 4.1: Original Image.  $\mathcal{H}_y = 0,207231$ ,  $SSIM_R = 1$ ,  $SSIM_G = 1$ ,  $SSIM_B = 1$

0.45mm

(a) t



Figura 4.2: Enhanced Image.  $\mathcal{H}_y = 0,611275$ ,  $SSIM_R = 0,00897331$ ,  $SSIM_G = 0,00823064$ ,  $SSIM_B = 0,00851013$

width=45mm

(a) t

Tabla 4.2: Coeficientes de las métricas obtenidas utilizando CMOPSO-CLAHE para algunos resultados no dominados de la imagen en la Figura (4.5), además de los coeficientes obtenidos con el enfoque de [MB], el cual se muestra en la última línea.

	$\mathcal{H}_y$	$SSIM_R$	$SSIM_G$	$SSIM_B$
Result 1	0.544854	0.0155038	0.0140995	0.0149364
Result 2	0.658577	0.00551113	0.00494194	0.00529456
Result 3	0.0425715	0.394656	0.380667	0.39842
Result 4	0.0365424	0.401675	0.388628	0.402692
Result 5	0.0350595	0.416776	0.403636	0.417654
Result 6	0.611275	0.00897331	0.00823064	0.00851013
Result 7	0.0342894	0.420948	0.408035	0.421891
Result Mono	0.788927	0.000204143	0.0000526475	0.0000518143




Figura 4.6: Frente Pareto dibujado utilizando datos de la Tabla 4.2

Tabla 4.3: Tabla de correlación entre métricas. Los datos fueron tomados de la Tabla 4.2.

Metrics	$\mathcal{H}_y$	$SSIM_R$	$SSIM_G$	$SSIM_B$
$\mathcal{H}_y$	1			
$SSIM_R$	-0.9826	1		
$SSIM_G$	-0.9823	0.9999	1	
$SSIM_B$	-0.9826	0.9999	0.9999	1

La Figura (4.6) muestra el Frente pareto creado a partir de los datos de la Tabla 4.2, y también la Tabla 4.3 muestra la correlación entre métricas, analizadas a partir de los resultados de la Tabla 4.2. Es notable cómo hay una correlación positiva muy fuerte entre  $SSIM_R$ ,  $SSIM_G$  y  $SSIM_B$ ; también existe una correlación negativa entre las métricas previamente mencionadas y  $\mathcal{H}_y$ . Éstas correlaciones indican que los canales  $R, G, B$  de las imágenes se ven afectadas directamente por el proceso que modifica el canal  $Y$  (see Algorithm (1)). Ésto también indica que la Mejora del Contraste de las imágenes a color se puede plantear como un problema de optimización bi-objetivo, utilizando simplemente  $\mathcal{H}_y$  y  $SSIM$  aplicados sobre el canal  $Y$ .

## Capítulo 5

# CONCLUSIONES Y TRABAJOS FUTUROS

Se presentó un enfoque de Mejora de Contraste Basada en Optimización Multi-objetivo, el cual toma en cuenta la intensidad y la información de color como métricas Multi-Objetivo. Éste enfoque logra un grupo de imágenes resultantes, con diferentes niveles de compromiso entre contraste y similaridad estructural, de manera a maximizar la información disponible para el análisis posterior.

Los autores aún realizan pruebas con imágenes similares encontradas en la base de datos. Como trabajos futuros, sería útil analizar los parámetros utilizados por las metaheurísticas, el uso de métricas no marginales para evaluar las imágenes resultantes obtenidas mediante éste enfoque; y además realizar pruebas planteando la Mejora de contraste de imágenes a color como un problema de optimización bi-objetivo.

### 5.1. Trabajos futuros

# REFERENCIAS BIBLIOGRÁFICAS

- [Bra00] Gary Bradski. The opencv library. *Dr. Dobb's Journal: Software Tools for the Professional Programmer*, 25(11):120–123, 2000.
- [DNA10] Juan J Durillo, Antonio J Nebro, and Enrique Alba. The jmetal framework for multi-objective optimization: Design and architecture. In *Evolutionary Computation (CEC), 2010 IEEE Congress on*, pages 1–8. IEEE, 2010.
- [Doi07] Kunio Doi. Computer-aided diagnosis in medical imaging: historical review, current status and future potential. *Computerized medical imaging and graphics*, 31(4):198–211, 2007.
- [EW93] Robert R Edelman and Steven Warach. Magnetic resonance imaging. *New England Journal of Medicine*, 328(10):708–716, 1993. PMID: 8433731.
- [GW02a] Rafael C. Gonzalez and Richard E. Woods. *Digital Image Processing (2nd Ed)*. Prentice Hall, 2002.
- [GW02b] Rafael C Gonzalez and Richard E Woods. *Processing*, 2002.
- [HS13] Pourya Hoseini and Mahrokh G. Shayesteh. Efficient contrast enhancement of images using hybrid ant colony optimisation, genetic algorithm, and simulated annealing. *Digital Signal Processing*, 23(3):879 – 893, 2013.
- [KBD91] A. Khellaf, A. Beghdadi, and H. Dupoisot. Entropic contrast enhancement. *IEEE Transactions on Medical Imaging*, 10(4):589–592, Dec 1991.
- [Kim97] Yeong-Taeg Kim. Contrast enhancement using brightness preserving bi-histogram equalization. *IEEE Transactions on Consumer Electronics*, 43(1):1–8, Feb 1997.
- [LKC14] Thomas Lillesand, Ralph W Kiefer, and Jonathan Chipman. *Remote sensing and image interpretation*. John Wiley & Sons, 2014.

- [MB] LG Moré and MA Brizuela. Pso applied to parameter tuning of clahe based on entropy and structural similarity index.
- [MBA<sup>+</sup>15] Luis G More, Marcos A Brizuela, Horacio Legal Ayala, Diego P Pinto-Roa, and Jose Luis Vazquez Noguera. Parameter tuning of clahe based on multi-objective optimization to achieve different contrast levels in medical images. In *Image Processing (ICIP), 2015 IEEE International Conference on*, pages 4644–4648. IEEE, 2015.
- [NDGN<sup>+</sup>09] Antonio J Nebro, Juan José Durillo, Jose Garcia-Nieto, CA Coello Coello, Francisco Luna, and Enrique Alba. Smpso: A new pso-based metaheuristic for multi-objective optimization. In *Computational intelligence in multi-criteria decision-making, 2009. mcdm'09. iee symposium on*, pages 66–73. IEEE, 2009.
- [PAA<sup>+</sup>87] Stephen M Pizer, E Philip Amburn, John D Austin, Robert Cromartie, Ari Geselowitz, Trey Greer, Bart ter Haar Romeny, John B Zimmerman, and Karel Zuiderveld. Adaptive histogram equalization and its variations. *Computer vision, graphics, and image processing*, 39(3):355–368, 1987.
- [Sai99] F. Saitoh. Image contrast enhancement using genetic algorithm. In *Systems, Man, and Cybernetics, 1999. IEEE SMC '99 Conference Proceedings. 1999 IEEE International Conference on*, volume 4, pages 899–904 vol.4, 1999.
- [WBSS04] Zhou Wang, Alan C Bovik, Hamid R Sheikh, and Eero P Simoncelli. Image quality assessment: from error visibility to structural similarity. *IEEE transactions on image processing*, 13(4):600–612, 2004.
- [Zui94] Karel Zuiderveld. Contrast limited adaptive histogram equalization. In *Graphics gems IV*, pages 474–485. Academic Press Professional, Inc., 1994.

## ANEXO A: Resultados extendidos

Los resultados de este apartado son los promedios de los tiempos de ejecución, de los algoritmos *Histogram Equalization* (HE), *Multiscale Morphological Contrast Enhancement* (MMCE) y el algoritmo propuesto, para las 200 imágenes en escala de grises. Los algoritmos se implementaron con el framework ImageJ y se hizo ejecutar 5 veces los experimentos. En la Tabla 1 se muestran los promedios de los tiempos de ejecución del algoritmo HE para las imágenes en escala de grises.

Tabla 1: Promedios de los tiempos de ejecución de algoritmo HE para las imágenes en escala de grises.

Nº de ejecución	t (ms)
1	1,145
2	0,945
3	0,97
4	0,925
5	0,95
Promedio	<b>0.987</b>

En la Tabla 2 se muestran los promedios de los tiempos de ejecución del algoritmo MMCE para las imágenes en escala de grises.

Tabla 2: Promedios de los tiempos de ejecución del algoritmo MMCE para las imágenes en escala de grises.

Iter. (n)	Nº de ejecuciones para el algoritmo MMCE					Promedios t(ms)
	1	2	3	4	5	
1	64,265	62,625	61,61	62,285	62,295	<b>62,616</b>
2	165,805	171,24	169,655	170,515	170,295	<b>169,502</b>
3	327,975	334,19	334,75	332,045	333,275	<b>332,447</b>
4	564,035	574,15	571,185	573,45	568,735	<b>570,311</b>
5	975,845	972,035	979,205	968,975	986,805	<b>976,573</b>
6	1454,415	1471,145	1449,78	1452,97	1463,74	<b>1458,41</b>
7	2037,11	2032,775	2041,54	2029,07	2038,735	<b>2035,846</b>



En la Tabla 3 se muestran los promedios de los tiempos de ejecución del algoritmo propuesto para las imágenes en escala de grises.

Tabla 3: Promedios de los tiempos de ejecución del algoritmo propuesto para las imágenes en escala de grises.

Iter. (n)	N° de ejecuciones para el algoritmo propuesto					Promedios t(ms)
	1	2	3	4	5	
1	62,105	63,055	61,99	62,445	62,955	62,51
2	166,74	169,645	168,34	168,435	169,34	168,5
3	327,175	332,58	331,765	332,755	331,52	331,159
4	565,245	576,84	574,47	573,6	572,15	572,461
5	976,57	973,22	968,35	970,245	975,26	972,729
6	1463,175	1474,82	1458,765	1459,83	1470,06	1465,33
7	2047,435	2040,82	2041,915	2039,95	2044,16	2042,856

# ANEXO B: Algoritmos que modifican el histograma

## .1. *Histogram Equalization* (HE)

El algoritmo HE, que estira el rango dinámico de intensidad, es el método más popular para mejorar el contraste de la imagen. El procedimiento estándar de la ecualización del histograma consiste en reasignar las escalas de grises de la imagen de entrada de modo que el histograma de la imagen de salida se aproxime al de la distribución uniforme, dando como resultado la mejora de la calidad subjetiva para la imagen de salida. La ecualización del histograma, sin embargo, introduce algunos efectos visuales indeseables y sobre-mejora. Pueden producirse grandes picos del histograma en áreas relativamente homogéneas, como el fondo liso, y se puede causar un aumento excesivo de las imágenes totalmente oscuras o brillantes.

## .2. *Contrast Limited Adaptive Histogram Equalization* (CLAHE)

El CLAHE permite evitar los inconvenientes causados en el procesamiento de la imagen mediante el algoritmo HE. En este método, la imagen se divide en subimágenes o bloques, y se realiza la ecualización del histograma a cada subimagen o bloque. A continuación, los mecanismos de bloqueo entre bloques vecinos se minimizan mediante filtrado o interpolación bilineal. CLAHE introdujo un límite de ajuste para superar el problema de ruido. El CLAHE limita la amplificación cortando el histograma en un valor predefinido antes de calcular la función de distribución acumulativa (CDF). Esto limita la pendiente del CDF y por lo tanto de la función de transformación. El valor en el que se recorta el histograma, el denominado límite de ajuste, depende de la normalización del histograma y, por tanto, del tamaño de la región vecinal. La redistribución volverá a empujar algunos contenedores por encima del límite de ajuste, resultando en un límite de ajuste efectivo que es mayor que el límite prescrito y cuyo valor exacto depende de la imagen. El CLAHE tiene dos parámetros claves: tamaño de bloque y límite

de ajuste. Estos parámetros se utilizan para controlar la calidad de la imagen y son seleccionados por el usuario.