



DIP/FPUNA

**MEJORA DEL CONTRASTE DE IMÁGENES A COLOR
UTILIZANDO UN FRAMEWORK DE OPTIMIZACIÓN
MULTIOBJETIVO**

Luis Guillermo Moré Rodríguez

Orientador: Prof. Diego Pedro Pinto Roa, Dr.

Tesis presentada a la Facultad Politécnica de la Universidad Nacional de Asunción, como requisito para la obtención del Grado de Máster en Ciencias de la Computación.

ASUNCIÓN - PARAGUAY

Noviembre - 2017

**MEJORA DEL CONTRASTE DE IMÁGENES A COLOR
UTILIZANDO UN FRAMEWORK DE OPTIMIZACIÓN
MULTIOBJETIVO**

Luis Guillermo Moré Rodríguez

Aprobado en Agosto de 2017 por:

Datos internacionales de Catalogación en la Publicación (CIP)
DE BIBLIOTECA CENTRAL DE LA UNA

Moré Rodríguez,Luis Guillermo

Mejora del contraste de imágenes a color utilizando un framework de optimización multiobjetivo/Luis Guillermo Moré Rodríguez. – Asunción, 2017.
22 p. : il.

Tesis (Maestría en Ciencias de la Computación) – Facultad Politécnica ,
2017.

Bibliografía.

1. Mejora de contraste. 2. Optimización Por Ejambre de Partículas. 3.
Imágenes a color. I. Título.

CDD 519.4

Dedicado a mi esposa Maura Soledad y a mis hijos Julio, Maira y Melisa.

Ustedes son el motor que me empuja hacia adelante.

Los amo.

Dedicado a mis padres Lino y María Egberta Ester.

Gracias por brindarme en esta vida su apoyo incondicional.

Julio César

Agradecimientos

Agradezco profundamente a Dios y a la Virgen María por todas las gracias que me han brindado, entre ellas mi gran familia, amigos, orientadores, profesores y colaboradores que hicieron posible este trabajo.

Agradezco al NIDTEC por brindarme la oportunidad.

Agradezco al CONACYT por la beca otorgada.

**MEJORA DEL CONTRASTE DE IMÁGENES A COLOR
UTILIZANDO UN FRAMEWORK DE OPTIMIZACIÓN
MULTIOBJETIVO**

Autor: Luis Guillermo Moré
Rodríguez

Orientador: Diego Pedro Pinto Roa, Dr.

RESUMEN

[INSERTE ABSTRACT AQUI]

**CONTRAST ENHANCEMENT OF COLOR IMAGES USING A
MULTI-OBJECTIVE OPTIMIZATION FRAMEWORK**

Author: Luis Guillermo Moré Rodríguez

Advisor: Diego Pedro Pinto Roa, Dr.

SUMMARY

[INSERT ABSTRACT HERE]

ÍNDICE GENERAL

LISTA DE FIGURAS	X
LISTA DE TABLAS	XI
LISTA DE SÍMBOLOS	XII
LISTA DE ABREVIATURAS	XIV
1. INTRODUCCIÓN	1
1.1. Objetivos	2
1.1.1. Objetivo General	2
1.1.2. Objetivos específicos	2
1.2. Estructura de la tesis	3
2. MARCO TEÓRICO	4
2.1. Ecualización del Histograma	4
2.2. Espacios de Color Adoptados	4
2.2.1. Contrast Limited Adaptive Histogram Equalization (CLAHE)	6
2.2.2. Multi-Objective Particle Swarm Optimization (MOPSO) .	6
2.2.3. Entropía de la imagen	7
2.2.4. Índice de Similaridad Estructural	7
3. FORMULACIÓN DEL PROBLEMA PLANTEADO Y PRO-	
PUESTA	9
3.1. Formulación del problema planteado	9
3.2. Propuesta	10
4. RESULTADOS Y DISCUSIÓN	12
5. CONCLUSIONES Y TRABAJOS	
FUTUROS	16

5.1. Trabajos futuros	16
---------------------------------	----

REFERENCIAS BIBLIOGRÁFICAS	17
-----------------------------------	-----------

.1. <i>Histogram Equalization</i> (HE)	21
.2. <i>Contrast Limited Adaptive Histogram Equalization</i> (CLAHE) . . .	21

LISTA DE FIGURAS

1.1. Imagen en escala de grises e imagen con contraste mejorado para posterior utilización.	2
2.1. Cubo que representa al espacio de colores RGB	5
4.1. Enhanced Image using [MB]. $\mathcal{H}_y = 0,788927$, $SSIM_R = 0,000204143$, $SSIM_G = 0,0000526475$, $SSIM_B = 0,0000518143$	13
4.2. Imágenes original y resultantes para la imagen de prueba Casa 1 .	13
4.3. Frente Pareto dibujado utilizando datos de la Tabla 4.2	14

LISTA DE TABLAS

4.1.	Parámetros de entrada para <i>MOPSO</i>	12
4.2.	Parámetros de entrada para <i>MOPSO</i>	14
4.3.	Parámetros de entrada para <i>MOPSO</i>	14
1.	Promedios de los tiempos de ejecución de algoritmo HE para las imágenes en escala de grises.	19
2.	Promedios de los tiempos de ejecución del algoritmo MMCE para las imágenes en escala de grises.	19
3.	Promedios de los tiempos de ejecución del algoritmo propuesto para las imágenes en escala de grises.	20

LISTA DE SÍMBOLOS

f	Imagen original.....	??
\mathbb{Z}	Conjunto de números enteros	??
\mathbb{R}	Conjunto de números racionales	??
m	Valor asociado a un píxel dentro de un espacio de color	??
c	Componentes del valor asociado a un píxel.....	??
j	Nivel de intensidad	??
f_k	Componentes de f	??
L	Máximo nivel de intensidad de una imagen.....	??
$h_{f_k}(j)$	Histograma del canal f_k	??
n_j	Cantidad de ocurrencia de la intensidad j en f_k	??
g	Elemento estructurante	??
(u,v)	Coordenada espacial que representa un pixel de la imagen....	??
(s,t)	Coordenada espacial del elemento estructurante.....	??
$(f \oplus g)$	Dilatación de la imagen original f por un elemento estructurante g	??
$(f \ominus g)$	Erosión de la imagen original f por un elemento estructurante g	??
$(f \circ g)$	Apertura de la imagen original f por un elemento estructurante g	??
$(f \bullet g)$	Cierre de la imagen original f por un elemento estructurante g ??	??
WTH	Transformada de top-hat por apertura	??
BTH	Transformada de top-hat por cierre	??
f_E	Imagen con mejora de contraste.....	??
f_1	Componente R de f	??
f_2	Componente G de f	??
f_3	Componente B de f	??
w	Función de pesos	??
T	Transformada escalar de una imagen.....	??
n	Número de iteraciones	??
i	Índice de iteraciones	??

WTH_i	i -escalas de brillos	??
BTH_i	i -escalas de oscuridad	??
WTH_{i-1}^S	$(i - 1)$ -diferencias en cascada de las escalas de brillo	??
BTH_{i-1}^S	$(i - 1)$ -diferencias en cascada de las escalas de oscuridad	??
WTH_M	Valores máximos de todas las escalas de brillos	??
BTH_M	Valores máximos de todas las escalas de oscuridad	??
WTH_M^S	Valores máximos de todas las escalas de brillos por sustracción	??
BTH_M^S	Valores máximos de todas las escalas de oscuridad por sustracción	??
	??	
$E(f)$	Intensidad media de la imagen f	??
$P(j)$	Probabilidad de ocurrencia del valor j	??
ρ	Valor del píxel central dentro de una ventana	??
ι	Valor medio de los vecinos de ρ	??
ω	Contraste local	??
D	Dominio de una imagen	??
γ	Diferencia entre los canales f_1 y f_2 de una imagen	??
β	Diferencia entre un medio de $(f_1 + f_2)$ y f_3	??
σ_γ	Desviación estándar de γ	??
σ_β	Desviación estándar de β	??
μ_γ	Media aritmética de γ	??
μ_β	Media aritmética de β	??

LISTA DE ABREVIATURAS

RGB: Espacio de color RGB.

HSI: Espacio de color HSI.

HSV: Espacio de color HSV.

HE: *Histogram Equalization*.

CLAHE: *Contrast-Limited Adaptive Histogram Equalization*.

MMCE: *Multiscale Morphological Contrast Enhancement*.

C: *Contrast*.

CIR: *Contrast Improvement Ratio*.

CEF: *Color Enhancement Factor*.

Capítulo 1

INTRODUCCIÓN


En el Procesamiento Digital de Imágenes, la Mejora del Contraste es un proceso que consiste en la transformación de píxeles de una imagen, con la finalidad de realizar cambios de manera tal a resaltar uno o más objetos dentro de la imagen tratada. El objetivo principal del proceso de Mejora del Contraste es la de obtener una nueva imagen cuyo Contraste sea más adecuado para la aplicación específica que se utilizará después [GW02a]

La Mejora del Contraste es un paso de preprocesamiento fundamental para varias aplicaciones. Algunas de las aplicaciones que más se benefician de éste proceso se detallan a continuación:

- Imágenes Médicas (como ejemplos es posible tomar: el Diagnóstico Asistido por Computadora [Doi07], Imágenes de Tomografía Computarizada [EW93], y otros).
- Sensoreamiento Remoto [LKC14],
- Imágenes aéreas,
- Imágenes astronómicas,
- Imágenes biométricas,
- Otras.

Las técnicas basadas en Ecualización del Histograma se mostraron extensivamente válidas para enfocar los problemas de Mejora del Contraste [PAA⁺87, Zui94, Kim97]. Las Meta-Heurísticas tales como la Optimización Mono-Objetivo, y también la Optimización Multi-Objetivo fueron testeadas satisfactoriamente de manera a resolver problemas de Mejora del Contraste en imágenes en escala de

gris [MB, MBA⁺15, Sai99, HS13]. Sin embargo, la Optimización Multi-Objetivo aplicada a la Mejora del Contraste en imágenes a color supone dificultades adicionales, debido a que es necesario preservar la información de color presente dentro de dichas imágenes.



(a) Imagen Original

(b) Imagen con contraste mejorado

Figura 1.1: Imagen en escala de grises e imagen con contraste mejorado para posterior utilización.

Esta propuesta consiste en realizar pruebas de Mejora del Contraste con imágenes a color transformadas desde el espacio de colores *RGB* al espacio de colores *YCbCr* de manera a realizar la Mejora de Contraste basada en Optimización Multi-Objetivo. Contrast Limited Adaptive Histogram Equalization (CLAHE) se aplica sobre el canal *Y* de la imagen de prueba, de manera a modificar el contraste, y la imagen resultante se transforma nuevamente a *RGB* de forma a evaluar la Mejora del Contraste lograda, además de la similaridad entre canales de color.

1.1. Objetivos

1.1.1. Objetivo General

Desarrollar un algoritmo de mejora de contraste para imágenes a color, utilizando un enfoque de Metaheurística Multi-Objetiva pura.

1.1.2. Objetivos específicos

- Desarrollar un nuevo algoritmo de Mejora del Contraste de imágenes a color basado en Metaheurísticas Multi-Objetivo.
- Demostrar la factibilidad del enfoque de Mejora de Contraste de imágenes a color basado en Metaheurísticas Multi-Objetivo puras.

- Encontrar alternativas de implementación que ayuden a subsanar problemas inherentes a los enfoques basados en Metaheurísticas Multi-Objetivo, cuando la cantidad de objetivos sobrepasa a tres.

1.2. Estructura de la tesis

El trabajo, en las secciones siguientes se organiza de la siguiente manera: en el capítulo 2, los conceptos fundamentales de éste trabajo se presentan; en el capítulo 3.2 se presenta el problema de Mejora de Contraste, y el enfoque de éste trabajo se muestra; en el capítulo 4 se discute en detalle los resultados obtenidos, y finalmente en el capítulo 5 se hacen algunos comentarios finales.

Capítulo 2

MARCO TEÓRICO

Éste capítulo presenta una introducción a los conceptos principales utilizados en éste trabajo. Solamente se busca presentar los conceptos fundamentales, necesarios para comprender los detalles técnicos del mismo.

2.1. Ecualización del Histograma

2.2. Espacios de Color Adoptados

Los Espacios de Color [?] son representaciones de color de las imágenes digitales, que por lo general se aceptan mediante convención o por estándar de hecho. Por lo general, los Espacios de Color consisten en sistemas de coordenadas donde cada punto es un color representable dentro del Espacio.

El primer espacio importante a analizar en este trabajo es *RGB* (del inglés *Red, Green, Blue*). En el modelo *RGB*, cada color aparece como un componente primario del *Rojo, Verde* y *Azul*.




Figura 2.1: Cubo que representa al espacio de colores RGB .

Las imágenes originales se representan utilizando el espacio de colores RGB [GW02b], el cual es un arreglo de pixeles de color de tamaño $N \times M \times 3$. Cada pixel de color está representado por un elemento $[z_r \ z_g \ z_b]$ del arreglo previamente mencionado, donde z_r, z_g, z_b son los componentes rojo, verde y azul de un pixel de color en una ubicación específica. Las imágenes originales son luego transformadas al espacio de colores $YCbCr$ [GW02b], el cual es una representación ampliamente utilizada en el video digital. La principal ventaja es que en esta representación Y representa la información de luminancia de la imagen, mientras que el componente Cb representa la diferencia entre el componente azul y un valor de referencia, mientras que el componente Cr es la diferencia entre el componente rojo y un valor de referencia. Otra ventaja importante de ésta representación es que la conversión desde RGB , y nuevamente hacia RGB es directa:

$$\begin{bmatrix} Y \\ C_b \\ C_r \end{bmatrix} = \begin{bmatrix} 16 \\ 128 \\ 128 \end{bmatrix} + \begin{bmatrix} 65,481 & 128,553 & 24,966 \\ -37,797 & -74,203 & 112,000 \\ 112,000 & -93,786 & -18,214 \end{bmatrix} \begin{bmatrix} R \\ G \\ B \end{bmatrix} \quad (2.1)$$

$$\begin{bmatrix} R \\ G \\ B \end{bmatrix} = \begin{bmatrix} Y + 1,402 \cdot (C_r - 128) \\ Y - 0,34414 \cdot (C_b - 128) - 0,71414 \cdot (C_r - 128) \\ Y + 1,772 \cdot (C_b - 128) \end{bmatrix} \quad (2.2)$$

2.2.1. Contrast Limited Adaptive Histogram Equalization (CLAHE)

2.2.2. Multi-Objective Particle Swarm Optimization (MOPSO)

Multi-Objective Particle Swarm Optimization (*MOPSO*) [NDGN⁺09] es un algoritmo metaheurístico bien conocido. ES una metaheurística bio-inspirada que simula el comportamiento de las bandadas de pájaros. En *PSO*, cada solución potencial del problema que se trata se denomina *particle* y la población actual de soluciones se llama *swarm*. Cada partícula \vec{x} realiza una búsqueda dentro de un espacio de búsqueda Ω , y para cada generación t , cada solución \vec{x} se actualiza de acuerdo a:

$$\vec{x}_i(t) = \vec{x}_i(t-1) + \vec{v}_i(t) \quad (2.3)$$

Aquí, \vec{v} es un factor conocido como la velocidad, y está dado por:

$$\vec{v}_i(t) = w \cdot (t-1) + C_1 \cdot r_1 \cdot (\vec{x}_{p_i} - \vec{x}_i) + C_2 \cdot r_2 \cdot (\vec{x}_{g_i} - \vec{x}_i), \quad (2.4)$$

donde \vec{x}_{p_i} es la mejor solución que \vec{x}_i encontró hasta ahora, \vec{x}_{g_i} es la mejor solución que el enjambre completo encontró durante una iteración, w es un coeficiente conocido como el *peso de la inercia*, que controla la tasa de velocidad de la búsqueda de *PSO*; r_1 y r_2 son números aleatorios entre $[0, 1]$. Finalmente, C_1 Y C_2 son los coeficientes que controlan la ponderación entre partículas globales y locales durante la búsqueda.

En *MOPSO*, un *coeficiente de constricción* χ se adopta de manera a controlar la velocidad de la partícula, como se describe abajo:

$$\chi = \frac{2}{2 - \varphi - \sqrt{\varphi^2 - 4\varphi}} \quad (2.5)$$

donde

$$\varphi = \begin{cases} C_1 + C_2 & \text{if } C_1 + C_2 > 4 \\ 0, & \text{if } C_1 + C_2 \leq 4 \end{cases} \quad (2.6)$$

Además, la velocidad en *MOPSO* se acota con la siguiente ecuación de cons-

tricción de velocidad:

$$v_{i,j}(t) = \begin{cases} \text{delta}_j & \text{if } v_{i,j}(t) > \text{delta}_j \\ -\text{delta}_j, & \text{if } v_{i,j}(t) \leq \text{delta}_j \\ v_{i,j}(t), & \text{otherwise} \end{cases} \quad (2.7)$$

donde

$$\text{delta}_j = \frac{\text{upper_limit}_j - \text{lower_limit}_j}{2} \quad (2.8)$$

2.2.3. Entropía de la imagen

La entropía de la imagen [KBD91] es una métrica que mide cuánta información está representada dentro de la imagen. La entropía y el contraste se relacionan de manera muy cercana a la distribución de intensidad de las imágenes, por lo que esta métrica es capaz de verificar las variaciones de contraste como consecuencia de las transformaciones de la imagen.

Primero, es necesario definir el *Histograma* de intensidades de una imagen H como sigue: Sea c_1, c_2, \dots, c_n el conteo de pixeles con intensidades i_1, i_2, \dots, i_n respectivamente, y sea también:

$$p_i = \frac{c_i}{N}, \quad \sum_{i=1}^n c_i = N, \quad i = 1, 2, \dots, n, \quad (2.9)$$

donde N es la suma total de pixeles mostrados en una imagen I y n es cada nivel de intensidad representable por el espacio de colores de I . Entonces, H se define como la distribución de probabilidad en el que cada p_i representa la probabilidad de ocurrencia de una intensidad i . Entonces, la Entropía de la Imagen se define de la siguiente manera:

$$\mathcal{H} = - \sum_{i=0}^{n-1} p_i \log_2(p_i) \quad \mathcal{H} \in \{0, \dots, \log_2(n)\} \quad (2.10)$$

2.2.4. Índice de Similaridad Estructural

El *Índice de Similaridad Estructural* (*SSIM*) [WBSS04] es una métrica bien conocida que mide atributos importantes de la imagen tales como la *Luminancia*, *Contraste* y la *Estructura*. *SSIM* tiene como objetivo principal medir la distorsión agregada a la imagen como consecuencia del proceso de Mejora del Contraste. *SSIM* es calculado por regiones, por lo tanto, dadas dos imágenes I_x y T_y que re-

presentan una imagen original y una mejorada, respectivamente, el índice $SSIM$ se define como se muestra abajo:

$$SSIM(I, T) = \frac{(2\mu_{I_x}\mu_{T_y} + E_1)(2\sigma_{I_x T_y} + E_2)}{(\mu_{I_x}^2 + \mu_{T_y}^2 + E_1)(\sigma_{I_x}^2 + \sigma_{T_y}^2 + E_2)} \quad SSIM \in [0, 1] \quad (2.11)$$

donde μ_{I_x} , μ_{T_y} son los promedios de intensidad de I_x y T_y , respectivamente; $\sigma_{I_x}^2$ y $\sigma_{T_y}^2$ son las varianzas de intensidad para I_x y T_y , respectivamente; $\sigma_{I_x T_y}$ es la covarianza entre las intensidades I_x y T_y . $E_1 = (K_1 L^2)$, donde L es el rango dinámico de intensidades de los pixeles de la imagen, y $K_1 \ll 1$ es una constante pequeña; $E_2 = (K_2 L)^2$, y $K_2 \ll 1$; tanto E_1 como E_2 son constantes utilizadas para estabilizar la división cuando el denominador se acerca a cero.

Capítulo 3

FORMULACIÓN DEL PROBLEMA PLANTEADO Y PROPUESTA

En este capítulo se muestra una formulación del problema a resolver, además de la propuesta detallada de la implementación realizada.

3.1. Formulación del problema planteado

Dada una imagen a color I , con $M \times N$ píxeles, y un vector $\vec{x} = (\mathcal{R}_x, \mathcal{R}_y, \mathcal{C})$, donde \mathcal{R}_x y \mathcal{R}_y son regiones contextuales y \mathcal{C} es el *Clip Limit*, se busca un conjunto de soluciones no dominadas \mathcal{X} , que simultáneamente maximicen las funciones objetivo f_1, f_2, f_3, f_4 :

$$\mathcal{F} = [f_1(I, \vec{x}), f_2(I, \vec{x}), f_3(I, \vec{x}), f_4(I, \vec{x})]; \quad f_1, f_2, f_3, f_4 \in [0, 1] \quad (3.1)$$

donde:

- T_y es el mapa de intensidades mejoradas, al aplicar \vec{x} a I_y ; ésto es: $T_y = CLAHE(\vec{x}, I_y)$. T_y e I_y son los canales Y de la representación $YCbCr$ de las imágenes I y T , respectivamente,
- $f_1(I, \vec{x}) = \frac{\mathcal{H}(T)}{\log_2 L}$ es la Entropía Normalizada del mapa de intensidades mejoradas T_y , como se describió arriba,
- $f_2(I, \vec{x}) = SSIM(I_R, T_R)$ es la medición del $SSIM$ entre I_R y T_R . I_R y T_R son los canales R de las representaciones RGB de I y T , respectivamente,
- $f_4(I, \vec{x}) = SSIM(I_G, T_G)$ es la medición del $SSIM$ entre I_G y T_G . I_G y T_G son los canales G de las representaciones RGB de I y T , respectivamente,

- $f_2(I, \vec{x}) = SSIM(I_B, T_B)$ es la medición del $SSIM$ entre I_B y T_B . I_B y T_B son los canales G de las representaciones RGB de I y T , respectivamente,

Acotados por:

- $\mathcal{R}_x \in [2, \dots, M]$ dentro de \mathbb{N} ,
- $\mathcal{R}_y \in [2, \dots, N]$ dentro de \mathbb{N} ,
- $\mathcal{C} \in (0, \dots, 1]$ dentro \mathbb{R} .

3.2. Propuesta

Algorithm 1 MOPSO-CLAHE

Require: Imagen de entrada I , cantidad de partículas Ω , iteraciones t_{max}

```

1: Inicializar  $\omega$ ,  $c_1$ ,  $c_2$ ,  $t = 0$ ,  $lower\_limit_1$ ,  $lower\_limit_2$ ,  $lower\_limit_3$ ,  $upper\_limit_1$ ,  $upper\_limit_2$ ,  $upper\_limit_3$ ,  $\mathcal{X}$ 
2: while  $t < t_{max}$  do
3:   for cada  $i$ -ésima partícula do
4:     Calcular una nueva velocidad  $\vec{v}_i^t$  de la partícula utilizando las ecuaciones (2.4) and (2.7)
5:     Calculate new particle position  $\vec{x}_i^t$  using expression (2.3)
6:      $T = CLAHE(\vec{x}_i^t, I)$ 
7:      $f_i^t = f(I, \vec{x}_i^t)$ 
8:     if  $\vec{x}_i^t \succ \vec{x}_{p_i}$  then
9:       replace  $\vec{x}_{p_i}$  by  $\vec{x}_i^t$ 
10:    end if
11:    if  $\vec{x}_i^t \succ \vec{x}_{g_i}$  then
12:      Update the Pareto set  $\mathcal{X}$ 
13:    end if
14:     $t = t + 1$ 
15:  end for
16: end while
Ensure:  $\mathcal{X}$ 

```

El Algoritmo 1 muestra cómo PSO-CLAHE Color Multi-Objetivo (*CMOPSO-CLAHE*) es implementado, de manera a sintonizar los parámetros de *CLAHE*. Los parámetros recibidos por *CLAHE* son almacenados por una partícula $\vec{x} = (\mathcal{R}_x, \mathcal{Y}_x, \mathcal{C})$, la imagen original I se transforma a su representación $YCrCb$, y \vec{x} es aplicado al canal Y de la representación, de manera a obtener un mapa de intensidades Y_T , el cual es utilizado para realizar la transformación inversa hacia RGB , para así obtener la imagen resultante T . Las imágenes resultantes son evaluadas de acuerdo a las métricas \mathcal{H}_Y , $SSIM_R$, $SSIM_G$, $SSIM_B$, que son la entropía de las imágenes resultantes medidas en el canal Y de la representación $YCrCb$ de dichas imágenes, y $SSIM_R, SSIM_G, SSIM_B$ son las medidas $SSIM$

de las imágenes original y resultantes utilizando los canales R, G, B de las representaciones RGB de las imágenes. Las soluciones no dominadas se almacenan finalmente en el conjunto Pareto. El proceso de *CMOPSO* – *CLAHE* se repite hasta que se alcanza un criterio de parada.

Capítulo 4

RESULTADOS Y DISCUSIÓN

Tabla 4.1: Parámetros de entrada iniciales para CMOPSO-CLAHE.

Parámetro	Valor	Parámetro	Valor
$lower_limit_{\mathcal{R}_x}$	2	$upper_limit_{\mathcal{R}_x}$	$M/2$
$lower_limit_{\mathcal{R}_y}$	2	$upper_limit_{\mathcal{R}_y}$	$N/2$
$lower_limit_{\mathcal{C}}$	0	$upper_limit_{\mathcal{C}}$	0.5
Ω	100	t_{max}	100
$c_1\ min$	1.5	$c_1\ max$	2.5
$c_2\ min$	1.5	$c_2\ max$	2.5
$r_1\ min$	0.0	$r_1\ max$	1.0
$r_2\ min$	0.0	$r_2\ max$	1.0

Se realizaron pruebas utilizando 8 imágenes a color a partir del conjunto de datos disponible en <http://www.vision.caltech.edu/archive.html>. La tabla 4.1 muestra cómo *SMPSO* fué configurada para realizar las pruebas. Los detalles de implementación de *SMPSO* está disponible en [DNA10], mientras que los detalles de implementación para *CLAHE*, \mathcal{H} y *SSIM* están disponibles en [Bra00]. Para cada imagen de prueba, se realizaron 50 ejecuciones, y en promedio se encontraron 10 soluciones no dominadas. De las figuras (??,??,??) es realmente notable cómo se logra la Mejora del Contraste; también hay una relación de compromiso entre \mathcal{H} y $SSIM_R, SSIM_G, SSIM_B$. Es también notable a partir de la Figura (??) cómo los valores más altos de \mathcal{H} degradan severamente a la imagen, por lo que es necesario encontrar el balance correcto entre \mathcal{H} and $SSIM_R, SSIM_G, SSIM_B$. En la Figura (4.1) se muestra la imagen resultante mejorada utilizando la propuesta descrita en [MB]; es interesante remarcar que

la imagen resultante no alcanza una buena Mejora del Contraste; ésto es debido a que el enfoque Mono-Objetivo no utiliza la información del color de manera apropiada, y éste resultado es el mismo para otras imágenes de prueba. En la Tabla 4.2, se muestran los coeficientes de las métricas no dominadas, y en la última línea se muestran los coeficientes de métricas para la imagen (??), mejorada utilizando la propuesta Mono-Objetivo. A pesar de que se puede considerar que las métricas caen dentro del Frente Pareto, la información visual obtenida no es suficiente para afirmar que la propuesta mono-objetivo es factible para imágenes a color. Éstos resultados son similares en cada imagen de prueba utilizada.



(a) Imagen Original. $\mathcal{H}_y = 0,207231$, $SSIM_R = 1$, $SSIM_G = 1$, $SSIM_B = 1$



(b) Enhanced Image. $\mathcal{H}_y = 0,611275$, $SSIM_R = 0,00897331$, $SSIM_G = 0,00823064$, $SSIM_B = 0,00851013$



(c) Imagen mejorada. $\mathcal{H}_y = 0,0350595$, $SSIM_R = 0,416776$, $SSIM_G = 0,403636$, $SSIM_B = 0,417654$



(d) Imagen mejorada utilizando [MB]. $\mathcal{H}_y = 0,788927$, $SSIM_R = 0,000204143$, $SSIM_G = 0,0000526475$, $SSIM_B = 0,0000518143$

Figura 4.1: Enhanced Image using [MB]. $\mathcal{H}_y = 0,788927$, $SSIM_R = 0,000204143$, $SSIM_G = 0,0000526475$, $SSIM_B = 0,0000518143$

Figura 4.2: Imágenes original y resultantes para la imagen de prueba Casa 1

Tabla 4.2: Coeficientes de las métricas obtenidas utilizando CMOPSO-CLAHE para algunos resultados no dominados de la imagen en la Figura (4.2), además de los coeficientes obtenidos con el enfoque de [MB], el cual se muestra en la última línea.

	\mathcal{H}_y	$SSIM_R$	$SSIM_G$	$SSIM_B$
Result 1	0.544854	0.0155038	0.0140995	0.0149364
Result 2	0.658577	0.00551113	0.00494194	0.00529456
Result 3	0.0425715	0.394656	0.380667	0.39842
Result 4	0.0365424	0.401675	0.388628	0.402692
Result 5	0.0350595	0.416776	0.403636	0.417654
Result 6	0.611275	0.00897331	0.00823064	0.00851013
Result 7	0.0342894	0.420948	0.408035	0.421891
Result Mono	0.788927	0.000204143	0.0000526475	0.0000518143




Figura 4.3: Frente Pareto dibujado utilizando datos de la Tabla 4.2

Tabla 4.3: Tabla de correlación entre métricas. Los datos fueron tomados de la Tabla 4.2.

Metrics	\mathcal{H}_y	$SSIM_R$	$SSIM_G$	$SSIM_B$
\mathcal{H}_y	1			
$SSIM_R$	-0.9826	1		
$SSIM_G$	-0.9823	0.9999	1	
$SSIM_B$	-0.9826	0.9999	0.9999	1

La Figura (4.3) muestra el Frente pareto creado a partir de los datos de la Tabla 4.2, y también la Tabla 4.3 muestra la correlación entre métricas, analizadas a partir de los resultados de la Tabla 4.2. Es notable cómo hay una correlación positiva muy fuerte entre $SSIM_R$, $SSIM_G$ y $SSIM_B$; también existe una correlación negativa entre las métricas previamente mencionadas y \mathcal{H}_y . Éstas correlaciones indican que los canales R, G, B de las imágenes se ven afectadas directamente por el proceso que modifica el canal Y (see Algorithm (1)). Ésto también indica que la Mejora del Contraste de las imágenes a color se puede plantear como un problema de optimización bi-objetivo, utilizando simplemente \mathcal{H}_y y $SSIM$ aplicados sobre el canal Y .

Capítulo 5

CONCLUSIONES Y TRABAJOS FUTUROS

Se presentó un enfoque de Mejora de Contraste Basada en Optimización Multi-objetivo, el cual toma en cuenta la intensidad y la información de color como métricas Multi-Objetivo. Éste enfoque logra un grupo de imágenes resultantes, con diferentes niveles de compromiso entre contraste y similaridad estructural, de manera a maximizar la información disponible para el análisis posterior.

Los autores aún realizan pruebas con imágenes similares encontradas en la base de datos. Como trabajos futuros, sería útil analizar los parámetros utilizados por las metaheurísticas, el uso de métricas no marginales para evaluar las imágenes resultantes obtenidas mediante éste enfoque; y además realizar pruebas planteando la Mejora de contraste de imágenes a color como un problema de optimización bi-objetivo.

5.1. Trabajos futuros

REFERENCIAS BIBLIOGRÁFICAS

- [Bra00] Gary Bradski. The opencv library. *Dr. Dobb's Journal: Software Tools for the Professional Programmer*, 25(11):120–123, 2000.
- [DNA10] Juan J Durillo, Antonio J Nebro, and Enrique Alba. The jmetal framework for multi-objective optimization: Design and architecture. In *Evolutionary Computation (CEC), 2010 IEEE Congress on*, pages 1–8. IEEE, 2010.
- [Doi07] Kunio Doi. Computer-aided diagnosis in medical imaging: historical review, current status and future potential. *Computerized medical imaging and graphics*, 31(4):198–211, 2007.
- [EW93] Robert R Edelman and Steven Warach. Magnetic resonance imaging. *New England Journal of Medicine*, 328(10):708–716, 1993. PMID: 8433731.
- [GW02a] Rafael C. Gonzalez and Richard E. Woods. *Digital Image Processing (2nd Ed)*. Prentice Hall, 2002.
- [GW02b] Rafael C Gonzalez and Richard E Woods. *Processing*, 2002.
- [HS13] Pourya Hoseini and Mahrokh G. Shayesteh. Efficient contrast enhancement of images using hybrid ant colony optimisation, genetic algorithm, and simulated annealing. *Digital Signal Processing*, 23(3):879 – 893, 2013.
- [KBD91] A. Khellaf, A. Beghdadi, and H. Dupoisot. Entropic contrast enhancement. *IEEE Transactions on Medical Imaging*, 10(4):589–592, Dec 1991.
- [Kim97] Yeong-Taeg Kim. Contrast enhancement using brightness preserving bi-histogram equalization. *IEEE Transactions on Consumer Electronics*, 43(1):1–8, Feb 1997.
- [LKC14] Thomas Lillesand, Ralph W Kiefer, and Jonathan Chipman. *Remote sensing and image interpretation*. John Wiley & Sons, 2014.

- [MB] LG Moré and MA Brizuela. Pso applied to parameter tuning of clahe based on entropy and structural similarity index.
- [MBA⁺15] Luis G More, Marcos A Brizuela, Horacio Legal Ayala, Diego P Pinto-Roa, and Jose Luis Vazquez Noguera. Parameter tuning of clahe based on multi-objective optimization to achieve different contrast levels in medical images. In *Image Processing (ICIP), 2015 IEEE International Conference on*, pages 4644–4648. IEEE, 2015.
- [NDGN⁺09] Antonio J Nebro, Juan José Durillo, Jose Garcia-Nieto, CA Coello Coello, Francisco Luna, and Enrique Alba. Smpso: A new pso-based metaheuristic for multi-objective optimization. In *Computational intelligence in multi-criteria decision-making, 2009. mcdm'09. iee symposium on*, pages 66–73. IEEE, 2009.
- [PAA⁺87] Stephen M Pizer, E Philip Amburn, John D Austin, Robert Cromartie, Ari Geselowitz, Trey Greer, Bart ter Haar Romeny, John B Zimmerman, and Karel Zuiderveld. Adaptive histogram equalization and its variations. *Computer vision, graphics, and image processing*, 39(3):355–368, 1987.
- [Sai99] F. Saitoh. Image contrast enhancement using genetic algorithm. In *Systems, Man, and Cybernetics, 1999. IEEE SMC '99 Conference Proceedings. 1999 IEEE International Conference on*, volume 4, pages 899–904 vol.4, 1999.
- [WBSS04] Zhou Wang, Alan C Bovik, Hamid R Sheikh, and Eero P Simoncelli. Image quality assessment: from error visibility to structural similarity. *IEEE transactions on image processing*, 13(4):600–612, 2004.
- [Zui94] Karel Zuiderveld. Contrast limited adaptive histogram equalization. In *Graphics gems IV*, pages 474–485. Academic Press Professional, Inc., 1994.

ANEXO A: Resultados extendidos

Los resultados de este apartado son los promedios de los tiempos de ejecución, de los algoritmos *Histogram Equalization* (HE), *Multiscale Morphological Contrast Enhancement* (MMCE) y el algoritmo propuesto, para las 200 imágenes en escala de grises. Los algoritmos se implementaron con el framework ImageJ y se hizo ejecutar 5 veces los experimentos. En la Tabla 1 se muestran los promedios de los tiempos de ejecución del algoritmo HE para las imágenes en escala de grises.

Tabla 1: Promedios de los tiempos de ejecución de algoritmo HE para las imágenes en escala de grises.

Nº de ejecución	t (ms)
1	1,145
2	0,945
3	0,97
4	0,925
5	0,95
Promedio	0.987

En la Tabla 2 se muestran los promedios de los tiempos de ejecución del algoritmo MMCE para las imágenes en escala de grises.

Tabla 2: Promedios de los tiempos de ejecución del algoritmo MMCE para las imágenes en escala de grises.

Iter. (n)	Nº de ejecuciones para el algoritmo MMCE					Promedios t(ms)
	1	2	3	4	5	
1	64,265	62,625	61,61	62,285	62,295	62,616
2	165,805	171,24	169,655	170,515	170,295	169,502
3	327,975	334,19	334,75	332,045	333,275	332,447
4	564,035	574,15	571,185	573,45	568,735	570,311
5	975,845	972,035	979,205	968,975	986,805	976,573
6	1454,415	1471,145	1449,78	1452,97	1463,74	1458,41
7	2037,11	2032,775	2041,54	2029,07	2038,735	2035,846

En la Tabla 3 se muestran los promedios de los tiempos de ejecución del algoritmo propuesto para las imágenes en escala de grises.

Tabla 3: Promedios de los tiempos de ejecución del algoritmo propuesto para las imágenes en escala de grises.

Iter. (n)	N° de ejecuciones para el algoritmo propuesto					Promedios t(ms)
	1	2	3	4	5	
1	62,105	63,055	61,99	62,445	62,955	62,51
2	166,74	169,645	168,34	168,435	169,34	168,5
3	327,175	332,58	331,765	332,755	331,52	331,159
4	565,245	576,84	574,47	573,6	572,15	572,461
5	976,57	973,22	968,35	970,245	975,26	972,729
6	1463,175	1474,82	1458,765	1459,83	1470,06	1465,33
7	2047,435	2040,82	2041,915	2039,95	2044,16	2042,856

ANEXO B: Algoritmos que modifican el histograma

.1. *Histogram Equalization* (HE)

El algoritmo HE, que estira el rango dinámico de intensidad, es el método más popular para mejorar el contraste de la imagen. El procedimiento estándar de la ecualización del histograma consiste en reasignar las escalas de grises de la imagen de entrada de modo que el histograma de la imagen de salida se aproxime al de la distribución uniforme, dando como resultado la mejora de la calidad subjetiva para la imagen de salida. La ecualización del histograma, sin embargo, introduce algunos efectos visuales indeseables y sobre-mejora. Pueden producirse grandes picos del histograma en áreas relativamente homogéneas, como el fondo liso, y se puede causar un aumento excesivo de las imágenes totalmente oscuras o brillantes.

.2. *Contrast Limited Adaptive Histogram Equalization* (CLAHE)

El CLAHE permite evitar los inconvenientes causados en el procesamiento de la imagen mediante el algoritmo HE. En este método, la imagen se divide en subimágenes o bloques, y se realiza la ecualización del histograma a cada subimagen o bloque. A continuación, los mecanismos de bloqueo entre bloques vecinos se minimizan mediante filtrado o interpolación bilineal. CLAHE introdujo un límite de ajuste para superar el problema de ruido. El CLAHE limita la amplificación cortando el histograma en un valor predefinido antes de calcular la función de distribución acumulativa (CDF). Esto limita la pendiente del CDF y por lo tanto de la función de transformación. El valor en el que se recorta el histograma, el denominado límite de ajuste, depende de la normalización del histograma y, por tanto, del tamaño de la región vecinal. La redistribución volverá a empujar algunos contenedores por encima del límite de ajuste, resultando en un límite de ajuste efectivo que es mayor que el límite prescrito y cuyo valor exacto depende de la imagen. El CLAHE tiene dos parámetros claves: tamaño de bloque y límite

de ajuste. Estos parámetros se utilizan para controlar la calidad de la imagen y son seleccionados por el usuario.