



Facultad Politécnica - Universidad Nacional de Asunción

Mejora de Contraste de Imágenes a Color Usando un Framework de Optimización Multi-Objetivo

Luis G. Moré

lmore@pol.una.py

Dic 20, 2017

- 1 Introducción
- 2 Marco Teórico
- 3 Formulación del Problema Planteado
- 4 Propuesta
- 5 Resultados y discusión
- 6 Conclusiones
- 7 Trabajos Futuros

- 1 **Introducción**
- 2 Marco Teórico
- 3 Formulación del Problema Planteado
- 4 Propuesta
- 5 Resultados y discusión
- 6 Conclusiones
- 7 Trabajos Futuros



- La mejora del contraste es un proceso de transformación de la imagen, con el objetivo de obtener una nueva imagen con un contraste más definido.
- Se busca obtener imágenes más aptas para algún proceso posterior o toma de decisiones.
- La mejora del contraste es un área de investigación atractiva en el procesamiento de imágenes.

Problemática

Mejora del Contraste automática de imágenes a color.



- En las imágenes digitales en escala de gris solamente es necesario considerar la información representada por los niveles de intensidad de los píxeles.
- En las imágenes a color, es necesario además tener en cuenta la información de color representada, lo cual representa un problema adicional en el proceso.





Figure: Histograma de niveles de intensidad de una imagen.

- Una técnica importante para la Mejora del Contraste es la Ecualización del Histograma.
- Ésta técnica es directa y efectiva en el trabajo de Mejora del Contraste.
- Existen enfoques globales y locales de Ecualización del Histograma.
- Los enfoques locales son efectivos para el realce de detalles finos de la imagen digital.

Objetivo

Desarrollar un enfoque para obtención de parámetros adecuados de Mejora del Contraste.



- En éste trabajo se busca atacar el problema de la Mejora del Contraste de imágenes digitales a color con un enfoque de Optimización Multi-Objetivo aplicado sobre un algoritmo de Ecualización del Histograma local.
- Se busca lograr un balance entre el realce de detalles de la imagen digital y el mantenimiento de la información de intensidades y de color.

- 1 Introducción
- 2 Marco Teórico**
- 3 Formulación del Problema Planteado
- 4 Propuesta
- 5 Resultados y discusión
- 6 Conclusiones
- 7 Trabajos Futuros

Primeros pasos

Separación de información de intensidad - Selección de espacios de color



- Se realiza una separación de la información de intensidad de la información de color para el proceso de ecualización del histograma.
- Se adoptaron representaciones de color bien conocidas para operar sobre la información de color de la imagen digital:
 - *RGB (Red, Green, Blue)*
 - *YCbCr*

Red, Green, Blue (RGB)




Figure: *RGB* es un espacio de representación de colores cartesiano

Las imágenes digitales se representan inicialmente en *RGB*, por lo que se tiene un array de $N \times M \times 3$ pixeles de color.

Cada pixel se representa como un elemento

$[z_r \ z_g \ z_b]$ donde z_r, z_g, z_b son los componentes de rojo, verde y azul del pixel a color en una ubicación específica.

Red, Green, Blue (RGB)




Figure: Representación de colores de ejemplo en el espacio *RGB*

Ventajas

- Representación Sencilla
- Representación Bien conocida
- Implementación en varios lenguajes

$YCbCr$

- $YCbCr$ es un espacio de color definido a través de una transformación matemática de coordenadas, a partir de un espacio de color RGB asociado.
- La ventaja de ésta representación es que separa la información de intensidades de la imagen digital de la información de color presente.




Figure: Planos de componentes *rojo*, *verde* y *azul* en la representación RGB




Figure: Planos de componentes Y , C_b , C_r en la representación YCbCr

YCbCr

YCbCr es un espacio de color definido a través de una transformación matemática de coordenadas, a partir de un espacio de color *RGB* asociado.

Otra ventaja importante es que la conversión a partir de *RGB*, y luego de vuelta a *RGB* es directa:

$$\begin{bmatrix} Y \\ C_b \\ C_r \end{bmatrix} = \begin{bmatrix} 16 \\ 128 \\ 128 \end{bmatrix} + \begin{bmatrix} 65.481 & 128.553 & 24.966 \\ -37.797 & -74.203 & 112.000 \\ 112.000 & -93.786 & -18.214 \end{bmatrix} \begin{bmatrix} R \\ G \\ B \end{bmatrix} \quad (1)$$

$$\begin{bmatrix} R \\ G \\ B \end{bmatrix} = \begin{bmatrix} Y + 1.402 \cdot (C_r - 128) \\ Y - 0.34414 \cdot (C_b - 128) - 0.71414 \cdot (C_r - 128) \\ Y + 1.772 \cdot (C_b - 128) \end{bmatrix} \quad (2)$$

Contrast Limited Adaptive Histogram Equalization - CLAHE

Es un algoritmo de Mejora del Contraste de tipo local, diseñado para su aplicación en distintos tipos de imágenes.

Sus parámetros de entrada principales consisten en:

$$\begin{aligned} (\mathcal{R}_x, \mathcal{R}_y, \mathcal{C}) \quad & (\mathcal{R}_x, \mathcal{R}_y) \in ([2, M/2], [2, N/2]) \\ & \mathcal{C} \in [0, 256] \end{aligned} \quad (3)$$

donde

- $(\mathcal{R}_x, \mathcal{R}_y)$ son las dimensiones de la región de la imagen donde se realiza la Ecualización del Histograma.
- \mathcal{C} es el coeficiente de recorte del histograma previo al proceso, *Clip Limit*.

Entropía de la Imagen

- La Entropía de la imagen es una métrica que muestra la cantidad de información representada en la imagen digital.
- La entropía de la imagen y su contraste están relacionados a la distribución de intensidad de las imágenes digitales, por lo que esta métrica es apta para medir variaciones del contraste como consecuencia de transformaciones aplicadas a la misma.

Efecto de la variación de Entropía de la Imagen




Figure: $\mathcal{H} = 7,053228$




Figure: $\mathcal{H} = 7,953866$

Efecto de la variación de Entropía de la Imagen




Figure: $\mathcal{H} = 7,053228$

Figure: $\mathcal{H} = 7,953866$

Entropía de la Imagen

La Entropía de la Imagen se define como se muestra abajo:

$$\mathcal{H} = - \sum_{i=0}^{L-1} p_i \log_2(p_i) \quad \mathcal{H} \in [0, \log_2(L)] \quad (4)$$

donde

$$p_i = \frac{c_i}{M \times N}, \quad \sum_{i=1}^L c_i = M \times N, \quad i = 1, 2, \dots, L \quad (5)$$

L es la cantidad de niveles de intensidad representables en la imagen, $M \times N$ es la cantidad de pixeles de la imagen.

Structural Similarity Index - SSIM

Es una métrica local que mide atributos importantes de la imagen tales como la *Luminancia*, *Contraste* y la *Estructura*. El objetivo de *SSIM* es el de medir la distorsión de la imagen. Dadas una imagen de entrada I_x y una de salida T_y *SSIM* se define como se muestra abajo:

$$SSIM(I, T) = \frac{(2\mu_{I_x}\mu_{T_y} + E_1)(2\sigma_{I_xT_y} + E_2)}{(\mu_{I_x}^2 + \mu_{T_y}^2 + E_1)(\sigma_{I_x}^2 + \sigma_{T_y}^2 + E_2)} \quad SSIM \in [0, 1] \quad (6)$$

- μ_{I_x} es el promedio de intensidades de los pixeles,
- σ_{T_y} es la varianza intensidades de los pixeles,
- $\sigma_{I_xT_y}$ es la covarianza de intensidades de los pixeles.

Efecto de la variación de SSIM de la Imagen



Figure: $SSIM_R = 1$; $SSIM_G = 1$; $SSIM_B = 1$



Figure:
 $SSIM_R = 0.484719$; $SSIM_G = 0.525963$; $SSIM_B = 0.533241$

Multi-Objective Particle Swarm Optimization (MOPSO)

MOPSO es una meta-heurística que emula el comportamiento social de las bandadas de pájaros.

Cada partícula $\vec{x} = (\mathcal{R}_x, \mathcal{R}_y, \mathcal{C})$ realiza una búsqueda dentro de un conjunto de partículas Ω , y para cada generación t , cada solución \vec{x} se actualiza de acuerdo a:

$$\vec{x}_i(t) = \vec{x}_i(t-1) + \vec{v}_i(t) \quad (7)$$

Donde \vec{v} se conoce como el factor de velocidad, y está dado por:

$$\vec{v}_i(t) = w \vec{v}_i \cdot (t-1) + C_1 \cdot r_1 \cdot (\vec{x}_{p_i} - \vec{x}_i) + C_2 \cdot r_2 \cdot (\vec{x}_{g_i} - \vec{x}_i) \quad (8)$$



Multi-Objective Particle Swarm Optimization (MOPSO)

$$\vec{v}_i(t) = w \vec{v}_i(t-1) + C_1 \cdot r_1 \cdot (\vec{x}_{p_i} - \vec{x}_i) + C_2 \cdot r_2 \cdot (\vec{x}_{g_i} - \vec{x}_i) \quad (9)$$

Donde:



- w es el peso de la inercia (control de velocidad de partículas),
- C_1, C_2 son parámetros específicos que controlan el efecto de las partículas locales y globales,
- r_1, r_2 son variables que aleatorizan la búsqueda en el rango $[0,1]$.

Multi-Objective Particle Swarm Optimization (MOPSO)



Comportamiento de partículas en *PSO* Monobjetivo a través de la serie de iteraciones.

Multi-Objective Particle Swarm Optimization (MOPSO)



Comportamiento de partículas en *PSO* Monobjetivo a través de la serie de iteraciones.

- 1 Introducción
- 2 Marco Teórico
- 3 Formulación del Problema Planteado**
- 4 Propuesta
- 5 Resultados y discusión
- 6 Conclusiones
- 7 Trabajos Futuros

Formulación del Problema Planteado

Dada una imagen a color I , con $M \times N$ pixeles, se busca un conjunto de soluciones no dominadas \mathcal{X} (parámetros del algoritmo de ecualización), que maximiza simultáneamente las funciones objetivo f_1, f_2, f_3, f_4 :

$$\mathcal{P} = (\mathcal{X}) \longrightarrow \max[f_1(T_y), f_2(I_R, T_R), f_3(I_G, T_G), f_4(I_B, T_B)]; \quad (10)$$
$$f_1, f_2, f_3, f_4 \in [0, 1]$$

donde

- I es la imagen a la que se aplica el proceso de Mejora del Contraste, y T es una de las imágenes resultantes del proceso,

$$\mathcal{P} = (\mathcal{X}) \longrightarrow \max[f_1(T_y), f_2(I_R, T_R), f_3(I_G, T_G), f_4(I_B, T_B)]; \quad (11)$$
$$f_1, f_2, f_3, f_4 \in [0, 1]$$

donde

- T_y es el mapa de intensidades mejoradas, al aplicar \vec{x} a I_y ; ésto es: $T_y = CLAHE(\vec{x}, I_y)$. T_y e I_y son los canales Y de la representación $YCbCr$ de las imágenes I y T , respectivamente,
- $f_1(T_y) = \frac{\mathcal{H}(T_y)}{\log_2 L}$ es la Entropía Normalizada del mapa de intensidades mejoradas T_y
- $f_2(I_R, T_R) = SSIM(I_R, T_R)$ es la medición del $SSIM$ entre I_R y T_R . I_R y T_R son los canales R de las representaciones RGB de I y T , respectivamente,

$$\mathcal{P} = (\mathcal{X}) \longrightarrow \max[f_1(T_y), f_2(I_R, T_R), f_3(I_G, T_G), f_4(I_B, T_B)]; \quad (12)$$
$$f_1, f_2, f_3, f_4 \in [0, 1]$$

donde

- $f_3(I_G, T_G) = SSIM(I_G, T_G)$ es la medición del *SSIM* entre I_G y T_G . I_G y T_G son los canales G de las representaciones *RGB* de I y T , respectivamente,
- $f_4(I_B, T_B) = SSIM(I_B, T_B)$ es la medición del *SSIM* entre I_B y T_B . I_B y T_B son los canales G de las representaciones *RGB* de I y T , respectivamente,
- $\mathcal{R}_x \in [2, \dots, M/2]$ dentro de \mathbb{N} ,
- $\mathcal{R}_y \in [2, \dots, N/2]$ dentro de \mathbb{N} ,
- $\mathcal{C} \in (0, \dots, 256]$ dentro \mathbb{R} .

- 1 Introducción
- 2 Marco Teórico
- 3 Formulación del Problema Planteado
- 4 Propuesta**
- 5 Resultados y discusión
- 6 Conclusiones
- 7 Trabajos Futuros

Diagrama esquemático de CMOPSO - CLAHE

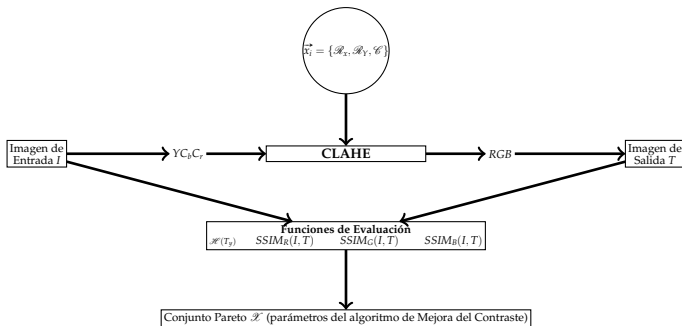


Figure: Proceso de evaluación de una solución potencial, para una iteración t de la implementación.

- 1 Introducción
- 2 Marco Teórico
- 3 Formulación del Problema Planteado
- 4 Propuesta
- 5 Resultados y discusión**
- 6 Conclusiones
- 7 Trabajos Futuros

Parámetros Iniciales

Table: Parámetros iniciales para CMOPSO – CLAHE

| Parámetro | Valor | Parámetro | Valor |
|--------------------------------|-------|--------------------------------|-------|
| M | 256 | N | 163 |
| $lower_limit_{\mathcal{R}_x}$ | 2 | $upper_limit_{\mathcal{R}_x}$ | $M/2$ |
| $lower_limit_{\mathcal{R}_y}$ | 2 | $upper_limit_{\mathcal{R}_y}$ | $N/2$ |
| $lower_limit_{\mathcal{C}}$ | 0 | $upper_limit_{\mathcal{C}}$ | 256 |
| Ω | 100 | t_{max} | 100 |
| $c_1\ min$ | 1.5 | $c_1\ max$ | 2.5 |
| $c_2\ min$ | 1.5 | $c_2\ max$ | 2.5 |
| $r_1\ min$ | 0.0 | $r_1\ max$ | 1.0 |
| $r_2\ min$ | 0.0 | $r_2\ max$ | 1.0 |



(a) Imagen Original.

$\mathcal{H}_y = 7,792769$, $SSIM_R = 1$,
 $SSIM_G = 1$, $SSIM_B = 1$



(b) Imagen Contrastada
utilizando CMOPSO – CLAHE.

$\mathcal{H}_y = 7,77002$,
 $SSIM_R = 0,894431$,
 $SSIM_G = 0,9022998$,
 $SSIM_B = 0,898023$

Figure: Imágenes original y contrastadas para calhouse_230.jpg

Resultados y discusión



(a) Imagen contrastada
utilizando CMOPSO – CLAHE.
 $\mathcal{H}_y = 7,9649405,$
 $SSIM_R = 0,583224,$
 $SSIM_G = 0,596364,$
 $SSIM_B = 0,582346$



(b) Imagen mejorada.
 $\mathcal{H}_y = 7,211073,$
 $SSIM_R = 0,999795857,$
 $SSIM_G = 0,9999473525,$
 $SSIM_B = 0,99994818587$

Figure: Imágenes original y contrastadas para calhouse_230.jpg




Figure: Gráfica de Frente Pareto para las variables de decisión obtenidas para la imagen calhouse_230.jpg

Table: Tabla de análisis de correlación entre métricas.

| Métricas | \mathcal{H}_y | $SSIM_R$ | $SSIM_G$ | $SSIM_B$ |
|-----------------|-----------------|----------|----------|----------|
| \mathcal{H}_y | 1 | | | |
| $SSIM_R$ | -0.9826 | 1 | | |
| $SSIM_G$ | -0.9823 | 0.9999 | 1 | |
| $SSIM_B$ | -0.9826 | 0.9999 | 0.9999 | 1 |

- Se puede notar la correlación positiva fuerte entre métricas de similaridad,
- Además se evidencia una correlación negativa entre la métrica de entropía y las de similaridad,
- Ésto se reproduce en todas las imágenes de prueba.

- Se encontraron parámetros solución con la mejor relación contraste/distorsión
- Se encontraron entre 100 y 250 soluciones no dominadas por imagen.
- La propuesta supera satisfactoriamente la etapa de prueba de concepto.
- La tabla de correlación de métricas sugiere que es posible realizar una implementación de mejora del contraste biobjetivo utilizando el canal de intensidades Y de $YCbCr$

- 1 Introducción
- 2 Marco Teórico
- 3 Formulación del Problema Planteado
- 4 Propuesta
- 5 Resultados y discusión
- 6 Conclusiones**
- 7 Trabajos Futuros

- La implementación propuesta demuestra ser satisfactoria para la realización de Mejora del Contraste Automática.
- Se obtienen los parámetros con buena relación inversa entre contraste/distorsión.
- La implementación es adecuada para la obtención de parámetros del algoritmo de mejora del contraste, aplicados sobre una imagen determinada.
- Los tiempos de entrenamiento son adecuados para lograr los resultados esperados.

- 1 Introducción
- 2 Marco Teórico
- 3 Formulación del Problema Planteado
- 4 Propuesta
- 5 Resultados y discusión
- 6 Conclusiones
- 7 Trabajos Futuros**

- Experimentar utilizando un enfoque de Mejora del Contraste de imágenes a color Biobjetivo basado en el canal de intensidades de alguna representación de color de imágenes digitales.
- Experimentar la Mejora de Contraste basada en Metaheurísticas utilizando métricas más adecuadas para la medición de la información de color de la imagen.
- Buscar mejoras en la eficiencia de los algoritmos de mejora de Contraste Basado en Metaheurísticas, en base a implementaciones de GPU, nuevas restricciones de las poblaciones de prueba, además de la cantidad de iteraciones impuestas a la metaheurística.

- Experimentar utilizando un enfoque de Mejora del Contraste de imágenes a color con metaheurísticas robustas.
- Buscar implementaciones que eviten el “efecto halo” detectado en ciertas imágenes que se obtienen como resultado de la propuesta.
- Buscar mejoras en la eficiencia de la implementación de La Mejora del Contraste basada en metaheurísticas, de manera a poder entrenar con imágenes de mayor tamaño.

Los resultados del trabajo se presentaron en los siguientes congresos:



Figure: 4th Conference of Computational Interdisciplinary Sciences - São José Dos Campos - Brasil - 2016



Figure: Mexican Internactional Conference of Artificial Intelligence - Ensenada, Baja California - México - 2017

¡Muchas Gracias!



Figure



Figure